INTRODUCCIÓN A LA CIENCIA DE LOS DATOS

PROYECTO 2 Y 3

Siniestralidad vial en Santiago de Cali, 2016-2024

Análisis exploratorio, limpieza y modelado de la gravedad de los siniestros

GRUPO DATOSSINCIENCIA

INTEGRANTES	CÓDIGO
Juan José Guzmán Camacho	**2380403**
Juan Pablo Rodríguez Gutiérrez	**2380422**
Natalia Martínez Castañeda	**2380414**
Jesus Ediber Arenas Guzmán	**2266066**
Juan José Wallens Serna	**2380556**

PROFESOR

Héctor Fabio Ocampo Arbeláez

ASIGNATURA

Introducción a la Ciencia de los Datos · Proyecto 2 y 3

REPOSITORIO

https://github.com/itspablito/DatosSinCiencia2y3

Santiago de Cali · Octubre de 2026

Siniestralidad vial en Santiago de Cali, 2016-2024

Análisis exploratorio, limpieza y modelado de la gravedad de los siniestros

Proyecto 2 y 3 · Ciencia de Datos · Grupo DatosSinCiencia · Octubre de 2026

1. Contexto del dataset y pregunta de negocio

El dataset reúne **370.996 reportes** de siniestros de tránsito recibidos por la Secretaría de Movilidad de Cali entre el 1 de enero de 2016 y el 2 de noviembre de 2024 (371.003 filas en el archivo original; se eliminaron 7 en la limpieza). Cada fila es un reporte con su fecha, dirección, clase de accidente, medio de reporte, número y tipo de vehículos implicados, y el resultado confirmado por el agente que acudió al sitio. El archivo viene en codificación Latin-1, separado por punto y coma, y marca los datos faltantes con un punto ("."). Este documento continúa el Proyecto 1, que exploró y modeló dimensionalmente el mismo dataset, y recoge las cuatro fases del Proyecto 2 y 3: análisis exploratorio, limpieza y normalización, modelos predictivos y conclusiones.

Variable objetivo: la gravedad del reporte, con cuatro clases ordenadas: *Negativo* (el agente acude y no se confirma un siniestro), *Solo daños*, *Con lesionado* y *Con fallecido*.

Pregunta de negocio: ¿qué características de un siniestro se asocian con su gravedad, para focalizar la prevención y priorizar la atención? Y como pregunta de modelado: ¿se puede estimar la gravedad de un reporte con los datos que se capturan hoy, y con qué nivel de confianza?

Clase de gravedad	Reportes	% del total
Negativo	246.107	66,3%
Solo daños	74.029	20,0%
Con lesionado	47.500	12,8%
Con fallecido	3.360	0,9%

Tabla 1. Distribución de la variable objetivo en los 370.996 reportes.

El desbalance condiciona todo el trabajo posterior: la clase que más importa para la ciudad (fallecidos) es la menos frecuente. Por eso los modelos se evalúan con F1 macro y con el *recall* de la clase "Con fallecido", y no solo con el accuracy.

2. Resumen del análisis exploratorio (Fase A)

El análisis exploratorio incluyó histogramas, boxplots con detección de atípicos por IQR, mapas de faltantes, correlación de Pearson y Spearman, y gráficos de barras, líneas, barras apiladas, Pareto, violín y barras horizontales. Cada gráfico del notebook lleva su interpretación en lenguaje de negocio; aquí se resume lo esencial.

Calidad de los datos

Solo la fecha y el resultado del reporte están completos. Los campos que describen *cómo* ocurrió el siniestro son los menos diligenciados, y los faltantes marcados con "." no son aleatorios: dependen del año, porque el formulario de captura cambió varias veces (la dirección no se registró entre 2018 y 2020, el medio de reporte solo existe desde 2021 y la clase de accidente solo está casi completa en 2024).

Campo	% sin dato	Comentario
Clase de accidente	87,7%	Casi completo solo en 2024
Medio de reporte	77,7%	Existe desde mayo de 2021
Tipo de vehículos implicados	59,9%	Lista de vehículos del reporte
Número de vehículos	52,4%	Se completó con la lista de vehículos en 109 filas
Dirección del reporte	49,5%	Texto libre, 65 mil valores distintos
Detalle del resultado confirmado	6,3%	Describe el resultado (fuga de datos)

Tabla 2. Porcentaje de datos faltantes por campo en el archivo original (Fase A).

Perfil de las variables numéricas

El dataset tiene una sola variable numérica original (el número de vehículos); las demás se construyeron a partir de la fecha y de la lista de vehículos. El siniestro típico es un choque entre dos vehículos (media 1,95 y mediana 2). Buses, camiones y bicicletas aparecen pocas veces (mediana 0), pero son muy asimétricos: la asimetría de las bicicletas es de 10,8, y la de carga y transporte público supera 3. Como casi todos los siniestros tienen exactamente 2 vehículos, el IQR es 0 y la regla IQR marca como atípico al 16% de los siniestros (unos 19.000 con un solo vehículo y unos 9.200 con tres o más). No son errores de captura sino siniestros reales, por lo que se conservan.

Variable	Media	Mediana	Desv. est.	Máximo	Asimetría
Número de vehículos	1,95	2	0,44	16	1,23
Motocicletas	0,52	0	0,62	5	0,80
Autos	1,16	1	0,79	5	0,13
Transporte público	0,09	0	0,31	5	3,25
Vehículos de carga	0,07	0	0,27	3	3,68
Bicicletas	0,01	0	0,09	2	10,80

Tabla 3. Estadísticos descriptivos de las variables de conteo (Fase A, antes de imputar).

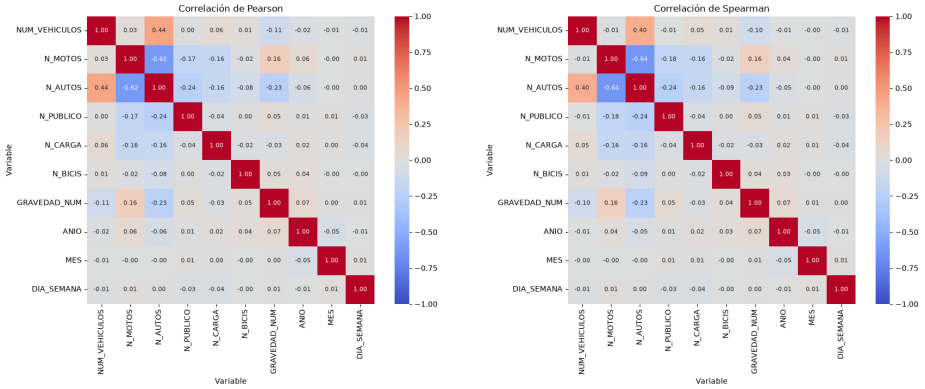


Figura 1. Correlación de Pearson (izquierda) y Spearman (derecha) entre las variables numéricas.

Las correlaciones con la gravedad son débiles pero coherentes en ambos métodos: positiva con motos (+0,16) y negativa con autos (-0,23). Las variables de calendario (mes, día de la semana) tienen correlación cercana a 0 con todo, y la relación entre motos y autos (cerca de -0,6) indica que comparten información. Se usa Spearman como referencia porque las variables son conteos sesgados y una ordinal. Correlación no implica causalidad.

Hallazgo 1. Motociclistas y ciclistas concentran la gravedad

Cuando hay una bicicleta implicada, el **60,3%** de los siniestros deja lesionados y el **3,2%** fallecidos; con una moto, 42,7% y 1,7%; cuando solo hay autos o camionetas, 11,5% y 0,3%. Una moto hace el siniestro unas cinco veces más letal. La correlación de Spearman con la gravedad confirma el patrón, porque el ocupante de un carro va más protegido. Además, automóviles y motocicletas suman el 84% de todos los vehículos implicados, y el transporte público también sobresale (30,4% con lesionados).

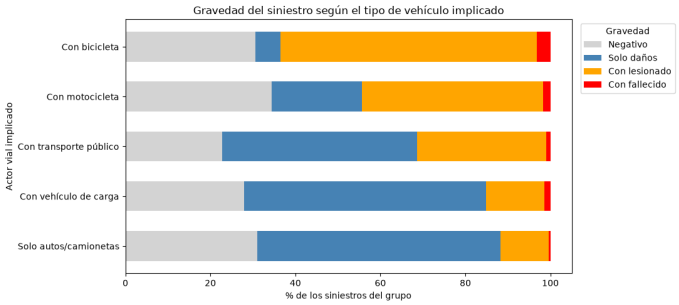


Figura 2. Gravedad según el actor vial implicado (Fase A, barras apiladas al 100%).

Hallazgo 2. Menos reportes no significa una ciudad más segura

El volumen mensual cae de unos 5.000 reportes a 2.500-3.000 desde marzo de 2020 y baja a unos 1.200 en 2024. Entre 2016 y 2023 los siniestros con fallecido se mantienen casi constantes (entre 362 y 451 por año, cerca de uno por día), mientras que los de "solo daños" casi desaparecen desde 2023 (de 5.464 en 2022 a 566 en 2023), cuando algunos reportes citan la Ley 2251 de 2022 para que los implicados resuelvan entre ellos los choques sin heridos. El indicador confiable a lo largo del tiempo es el de fallecidos. Los días con menos reportes (entre 1 y 5, del 30 de abril al 4 de mayo de 2021) coinciden con el Paro Nacional, cuando el sistema operó parcialmente; son atípicos reales y se conservan.

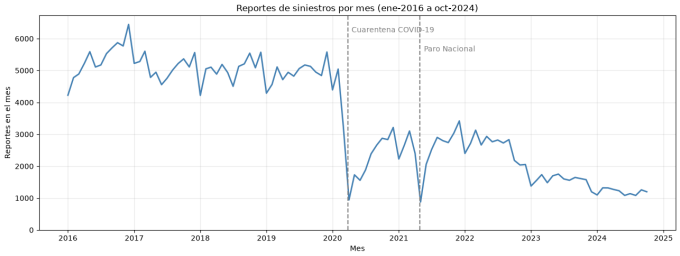


Figura 3. Reportes por mes, 2016-2024 (Fase A). Quiebre en marzo de 2020.

Hallazgo 3. La calidad del registro cambió con el tiempo y depende del resultado

Además de los faltantes por año, el dato de vehículos falta en el **81% de los reportes "Negativo"** pero solo en el 16-19% de los siniestros con lesionados o solo daños (y en el 55% de los fallecidos). Esto tiene una consecuencia directa para el modelado: un modelo puede "adivinar" que un reporte es Negativo a partir del hueco y no del siniestro. Por eso, en la Fase C estas variables y otras ligadas al registro del resultado se excluyen de los clasificadores. Otros hallazgos: el domingo es el día con menos reportes pero los más graves (1,4% con fallecidos, casi el doble que un jueves), y los atropellos y las caídas de ocupante dejan lesionados en cerca del 91% de los casos.

Clase de accidente	Reportes	Negativo	Solo daños	Con lesionado	Con fallecido
Caída de ocupante	1.476	7,5%	1,4%	91,0%	0,1%
Choque	32.631	47,0%	24,2%	27,7%	1,1%
Atropello	6.610	4,5%	2,4%	90,5%	2,6%
Volcamiento	1.938	12,7%	5,4%	78,2%	3,8%
Otro	203	34,5%	19,2%	14,8%	31,5%

Tabla 4. Gravedad según la clase de accidente (Fase A; solo los reportes que tienen este campo).

El volcamiento es la clase más letal entre las frecuentes y el choque, aunque es la más común, termina en su mayoría sin víctimas. La categoría "Otro" (31,5% con fallecido) es muy pequeña y parece usarse para casos registrados a partir del fallecimiento. Como esta variable solo existe en el 12% de los registros, su uso en el modelado es limitado. En cuanto a puntos críticos, la Calle 10 y la Calle 25 aparecen tres veces cada una entre las 15 direcciones con más reportes, lo que apunta a ejes completos más que a cruces aislados; dos de esas "direcciones" son clínicas, donde el caso se registra cuando llega el lesionado y no donde ocurrió, algo que debe depurarse antes de cualquier análisis geográfico.

3. Técnicas de limpieza y normalización (Fase B)

El pipeline parte de las 371.003 filas originales y termina en **370.996 filas y 34 variables numéricas sin faltantes**. El orden importa: el split 80/20 estratificado por gravedad se hace *antes* de imputar, transformar y escalar, y todo valor aprendido de los datos (medianas, modas, parámetros de Yeo-Johnson, medias y desviaciones) se calcula solo con las filas de entrenamiento. Así se evita la fuga de datos hacia el conjunto de prueba. El split dejó 296.796 reportes de entrenamiento y 74.200 de prueba, con la misma proporción de cada clase en ambos (66,34% Negativo, 19,95% Solo daños, 12,80% Con lesionado y 0,91% Con fallecido).

Paso	Decisión	Justificación
Estructura	"." a NaN; se eliminan 1 fila vacía, 4 duplicados exactos, 2 filas sin gravedad y la columna repetida	Un duplicado cuenta doble un siniestro. La variable objetivo nunca se imputa: sería inventar la respuesta.
Texto	Mayúsculas, sin tildes y diccionario por columna: clase 14 a 6 variantes, medio 17 a 4, vehículos 54 tipos a 6 grupos	Misma categoría escrita de varias formas (CHOQUE / Choque). Evita decenas de columnas casi vacías.
Dirección	Se extrae el tipo de vía (calle, carrera, avenida...); clínicas como CENTRO MEDICO	Con 65 mil direcciones distintas, One-Hot sería inviable. En clínicas el caso se registra donde llega el lesionado.
Nulos numéricos	Mediana de train + indicador SIN_DATO_VEHICULOS	Conteos asimétricos: la mediana no se mueve con los choques múltiples y es un entero. El indicador marca qué filas se imputaron.
Nulos categóricos	"SIN REGISTRO" donde el campo no existía; moda de train donde faltan datos sueltos	Los faltantes dependen del año y del resultado: imputar la moda inventaría cerca de 290 mil valores de medio de reporte.
Outliers	IQR y Z-score. Se conservan todos; solo 2 valores imposibles (12 y 16 vehículos) pasan a NaN	Con IQR = 0 la regla IQR marca como atípico el 16% de los datos que son normales. Los choques múltiples son reales.
Sesgo	Yeo-Johnson (ajustado con train) en conteos con asimetría > 1	log(1+x) invertía el sesgo de NUM_VEHICULOS (+1,12 a -1,54); Yeo-Johnson lo dejó en 0,50.
Encoding	Ordinal: gravedad y periodo del registro. One-Hot con drop_first=True: clase, medio, vía y día de la semana	Solo las variables con orden natural reciben números ordenados; el One-Hot evita distancias inexistentes entre categorías.
Escalado	Z-score: conteos. Min-Max: año, mes, periodo	Rangos comparables para modelos sensibles a la escala, como la regresión logística y K-Means. RobustScaler no aplica porque el IQR es 0.

Tabla 5. Resumen de las decisiones de limpieza y su justificación.

Manejo de valores nulos

Cada columna recibió la estrategia que corresponde a su tipo y a la razón por la que faltaba. Se usaron tres estrategias distintas (mediana, moda y categoría constante) y todas las medianas y modas se calcularon solo con train. KNN no se usó: las columnas de vehículos faltan juntas (sin lista tampoco hay conteos), los vecinos solo se distinguirían por la fecha, que no se relacionó con los vehículos (Spearman cercano a 0), y calcular distancias sobre unas 300 mil filas es costoso sin motivo para esperar algo mejor que la mediana.

Variable	% faltante antes	Estrategia	Después
NUM_VEHICULOS	52,4%	Mediana de train (2)	0%
N_MOTOS, N_AUTOS, N_PUBLICO, N_CARGA, N_BICIS, N_OTROS	59,9%	Mediana de train (autos: 1; el resto: 0) + indicador SIN_DATO_VEHICULOS	0%
MEDIO_REPORTE	77,7%	"SIN REGISTRO" antes de may-2021; luego la moda	0%
CLASE_ACCIDENTE	87,7%	Moda (CHOQUE) en 2024; "SIN REGISTRO" en el resto	0%
TIPO_VIA	49,5%	"SIN REGISTRO" (sin captura entre 2018 y 2020)	0%

Tabla 6. Faltantes antes y después de la imputación, con la estrategia de cada columna (Fase B).

Valores atípicos

Se aplicaron IQR y Z-score a los conteos de vehículos. La regla IQR falla en estas variables porque casi todo vale 0 o 2 y el IQR es 0; el Z-score marca los siniestros con 4 o más vehículos, que son choques en cadena reales. La decisión fue conservar todas las filas y corregir solo dos valores imposibles: los reportes con 12 y 16 vehículos son "Negativo", no tienen lista de vehículos y superan de lejos el máximo con lista (9), así que se tratan como error de captura y el número se imputó como cualquier otro faltante. El nuevo máximo es 9. Por número de vehículos, la regla IQR marca 28.244 siniestros y el Z-score 1.290.

Transformación, encoding y escalado

Seis conteos tenían asimetría mayor que 1 y se transformaron con Yeo-Johnson, ajustado solo con train. El logaritmo empeoraba el número de vehículos: como la mayoría vale 2, comprimía la cola derecha hasta invertir el sesgo (de +1,12 a -1,54, frente a 0,50 con Yeo-Johnson). En bicicletas, carga y transporte público ninguna transformación logra simetría, porque registran un evento raro (el vehículo estuvo o no en el siniestro). Después se codificaron las variables categóricas: la gravedad y el periodo del registro (2016-2019 < 2020-2022 < 2023-2024) como ordinales, y clase de accidente, medio de reporte, tipo de vía y día de la semana con One-Hot (*drop_first=True*), que creó 23 columnas. Por último, los conteos se estandarizaron con Z-score y año, mes y periodo con Min-Max, ajustando los escaladores solo con train. El resultado son 34 variables predictoras, 3 columnas de control y 2 columnas de objetivo, guardadas en *datos_limpios.parquet*.

4. Modelos entrenados y comparación de desempeño (Fase C)

Se entrenaron tres clasificadores para estimar la gravedad registrada de cada reporte, usando la partición de la Fase B y evaluando **solo en test**. Se conservó la columna *SPLIT* en lugar de repetir el *train_test_split*, porque las imputaciones y los escaladores se ajustaron con ese conjunto de entrenamiento y repartir otra vez mezclaría filas de prueba en el ajuste.

Variables de los modelos

Los modelos usan **20 variables**. Se excluyeron los identificadores, las dos representaciones del objetivo, la clase de accidente, el tipo de vía y el indicador de vehículos faltantes, porque pueden reflejar cómo se registró el resultado y no el siniestro (Hallazgo 3).

Grupo	Variables	Número
Conteos de vehículos	Número de vehículos, motos, autos, transporte público, carga, bicicletas y otros (los seis primeros transformados con Yeo-Johnson y estandarizados; autos solo estandarizado)	7
Tiempo	Año, mes y periodo del registro (Min-Max)	3
Medio de reporte	Línea 127, CAD 123, radio y otro (One-Hot)	4
Día de la semana	Martes a domingo (One-Hot; el lunes es la referencia)	6

Tabla 7. Las 20 variables predictoras de los modelos supervisados y de K-Means.

Los modelos son regresión logística, árbol de decisión (profundidad máxima 8) y Random Forest (200 árboles, profundidad máxima 8). Los tres usan *class_weight*="balanced" y semilla 42. Las configuraciones se fijaron antes de evaluar y no se hizo búsqueda de hiperparámetros. Como referencia, un modelo que siempre responde "Negativo" logra accuracy 0,6634 y F1 macro 0,1994. El test tiene 49.222 reportes Negativo, 14.806 Solo daños, 9.500 Con lesionado y 672 Con fallecido.

Modelo	Accuracy	Precision macro	Recall macro	F1 macro	F1 ponderado	AUC macro*
Regresión logística	0,7243	0,5107	0,6369	0,5230	0,7444	0,815
Árbol de decisión	**0,7270**	0,5164	0,6394	0,5287	**0,7469**	0,836
Random Forest	0,7256	**0,5182**	**0,6448**	**0,5303**	0,7458	0,841

Tabla 8. Métricas en el conjunto de prueba (74.200 reportes); en negrita, el mejor valor de cada columna. *AUC uno contra todos, promediado entre las 4 clases, calculado para el informe con las mismas configuraciones.

Los tres modelos superan con claridad la referencia, pero quedan **muy cerca entre sí**: el accuracy está entre 0,7243 y 0,7270 y el F1 macro entre 0,5230 y 0,5303. Random Forest tiene el mayor F1 macro, pero su ventaja frente al árbol es de solo 0,0016, y el árbol tiene el mayor accuracy. Ningún modelo domina en todos los criterios. La diferencia entre el accuracy (cerca de 0,73) y el F1 macro (cerca de 0,53) muestra por qué hay que examinar cada clase en un dataset desbalanceado.

Modelo	Negativo	Solo daños	Con lesionado	Con fallecido
Regresión logística	0,8467	**0,6089**	0,4661	0,1701
Árbol de decisión	**0,8491**	0,6004	0,4856	**0,1795**
Random Forest	0,8445	0,6039	**0,4956**	0,1773

Tabla 9. F1 por clase en el conjunto de prueba; en negrita, el mejor de cada clase.

El F1 baja con la frecuencia de la clase: de 0,84-0,85 en "Negativo" a solo 0,17-0,18 en "Con fallecido". Ningún modelo es el mejor en todas las clases: la regresión logística gana en "Solo daños", el árbol en "Negativo" y "Con fallecido", y Random Forest en "Con lesionado".

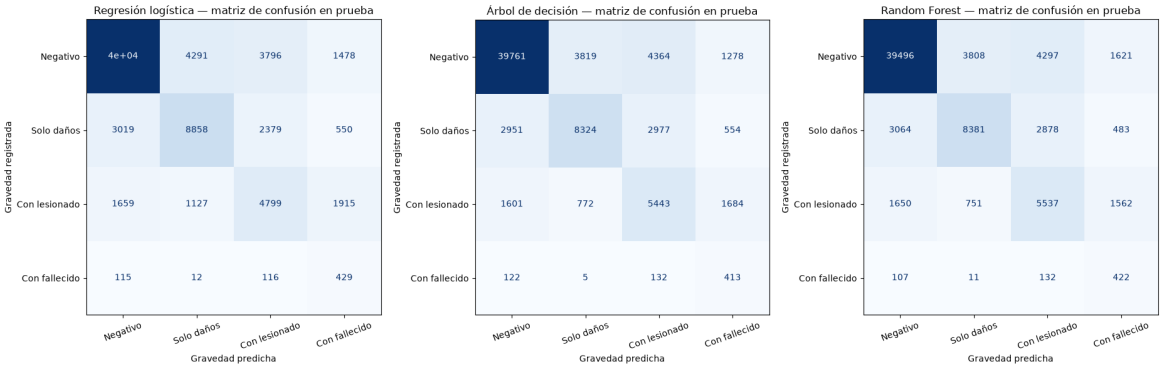


Figura 4. Matrices de confusión en test (número de reportes). Filas: gravedad registrada; columnas: gravedad predicha.

Las matrices muestran dónde se equivocan. "Negativo" se acierta en cerca del 80% de los casos. "Con lesionado" es la clase más difícil entre las frecuentes: el *recall* sube de 50,5% (regresión logística) a 57,3% (árbol) y 58,3% (Random Forest). En "Con fallecido" los errores van sobre todo hacia "Negativo" y "Con lesionado".

Desempeño en reportes con fallecido

Modelo	Precision	Recall	F1	Detectados (de 672)	Falsas alarmas
Regresión logística	0,0981	**0,6384**	0,1701	429	3.943
Árbol de decisión	**0,1051**	0,6146	**0,1795**	413	3.516
Random Forest	0,1032	0,6280	0,1773	422	3.666

Tabla 10. Clase "Con fallecido" en test.

Los modelos recuperan entre 61% y 64% de los reportes con fallecido, pero solo una de cada diez alertas de esa clase es correcta. Con Random Forest, 250 de los 672 casos fatales quedan clasificados en otra categoría y 3.666 reportes se marcan como fatales sin serlo. Con esa precisión, el modelo sirve para estudiar los registros, no como criterio único para decidir sobre un reporte individual.

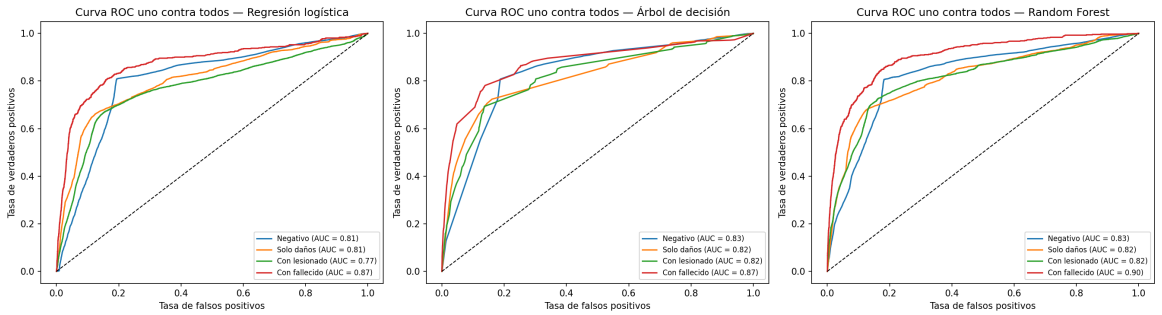


Figura 5. Curvas ROC uno contra todos en test (calculadas con las mismas configuraciones del notebook).

La curva ROC confirma que los modelos separan las clases mejor que el azar: el AUC de "Con fallecido" es de 0,87 a 0,90 según el modelo, mientras que las clases intermedias ("Solo daños" y "Con lesionado") quedan entre 0,77 y 0,82.

5. Segmentación no supervisada con K-Means

K-Means se aplicó sobre las mismas 20 variables, **sin usar la gravedad**. Se compararon de 2 a 10 grupos sobre una muestra reproducible de 10.000 reportes de entrenamiento (Silhouette sobre 2.000 de ellos), sin consultar el conjunto de prueba ni las etiquetas de gravedad. Con **k = 6** se obtuvo el mayor Silhouette (0,4334) y el menor Davies-Bouldin (0,6672); ambos criterios coinciden. Esta elección corresponde al rango, la muestra y las variables evaluadas, y no demuestra que existan exactamente seis grupos naturales.

k	Silhouette (mayor es mejor)	Davies-Bouldin (menor es mejor)	Inercia
2	0,3532	1,4542	72.329
3	0,3642	1,0238	61.670
4	0,3752	0,7997	50.922
5	0,4105	0,7333	40.359
6	**0,4334**	**0,6672**	31.456
7	0,3943	0,7511	25.976
8	0,4243	0,7332	21.770
9	0,2694	1,0229	20.587
10	0,3172	0,9796	18.228

Tabla 11. Selección del número de grupos (muestra de entrenamiento).

El modelo final se ajustó con todo el train y los reportes de test se asignaron a los centros aprendidos: sobre 2.000 reportes de test, Silhouette 0,4261 y Davies-Bouldin 0,6779, cercanos a los de la exploración aunque no equivalentes, porque se calculan sobre otra muestra. Estas métricas describen la estructura de los grupos, no la capacidad de predecir gravedad. En esa muestra de test hay solo 6 reportes del grupo 1 y 3 del grupo 5, por lo que las métricas dicen poco sobre ellos.

Cluster	Train	Test	Perfil destacado	Negativo	Solo daños	Con lesionado	Con fallecido
0	225.919	56.486	Mayor valor relativo de autos; posible mezcla con registros imputados	77,1%	17,1%	5,1%	0,7%
1	1.050	251	Bicicletas	29,9%	6,4%	**61,0%**	**2,8%**
2	10.155	2.526	Transporte público	22,5%	45,3%	31,2%	1,0%
3	8.330	2.078	Vehículos de carga	28,3%	56,9%	13,4%	1,4%
4	50.543	12.660	Motocicletas	34,6%	21,5%	42,3%	1,5%
5	799	199	Otros vehículos	24,9%	51,2%	22,7%	1,3%

Tabla 12. Tamaño y perfil de cada segmento. Las últimas cuatro columnas (porcentaje de cada gravedad dentro del cluster, en train) se calcularon para el informe; el notebook no las incluye.

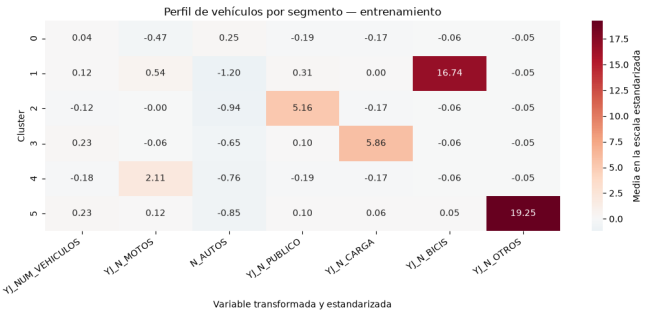


Figura 6. Perfil de vehículos por segmento (medias en escala estandarizada, entrenamiento).

Los seis segmentos se distinguen sobre todo por el actor vial: el grupo 4 destaca en motocicletas, el 2 en transporte público, el 3 en carga, el 1 en bicicletas y el 5 en otros vehículos. El grupo 0 concentra cerca del 76% de los reportes. Al cruzar los segmentos con la gravedad se ve lo mismo que en el análisis exploratorio: los grupos de bicicletas (61,0% con lesionados) y motos (42,3%) tienen mucha más gravedad que el grupo 0 (5,1%). Es una descripción, no una prueba de que el segmento cause el resultado, y los grupos 1 y 5 son pequeños (1.050 y 799 reportes de train), por lo que se leen con cautela. Las medias corresponden a variables transformadas, imputadas y estandarizadas, no a cantidades originales de vehículos.

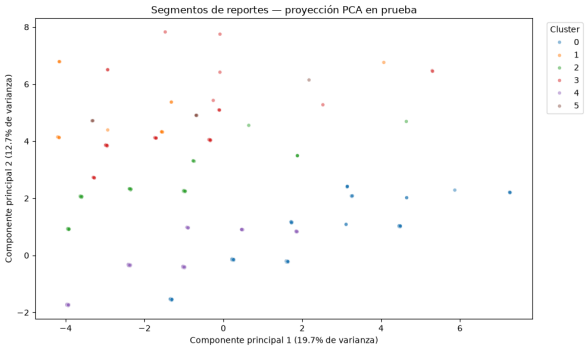


Figura 7. Segmentos K-Means en 2 componentes principales (5.000 reportes de test; 32,35% de la varianza).

La proyección PCA conserva solo el 32,35% de la varianza, y como casi todas las variables son discretas, muchos puntos se superponen: sirve para visualizar, no para comparar tamaños de grupos. Los segmentos pueden reflejar también diferencias de captura entre periodos, y sus números son identificadores, no niveles de riesgo.

6. Modelo elegido y justificación

Modelo final: Random Forest, entre las configuraciones evaluadas. Se eligió porque tiene el mayor F1 macro (0,5303), el criterio principal por dar el mismo peso a cada clase en un problema donde "Con fallecido" es solo el 0,91% de los reportes. También tiene la mayor Precision macro, el mayor Recall macro y el mayor F1 para "Con lesionado" (0,4956). La decisión tiene límites claros:

- La ventaja sobre el árbol es de solo **0,0016** de F1 macro y viene de una sola partición, así que no demuestra superioridad consistente. Si el criterio fuera la simplicidad y la lectura de reglas, el **árbol de decisión** es una alternativa razonable: tiene el mayor accuracy (0,7270) y el mayor F1 para fallecidos (0,1795).
- La **regresión logística** es la más simple de explicar y alcanza el mayor *recall* en fallecidos (63,8%), a costa de más falsas alarmas (3.943).
- Random Forest no es el mejor en fallecidos y su precisión en esa clase es de 10,3%: es un resultado experimental del proyecto, no una herramienta para decidir sobre casos individuales.

El ejercicio **clasifica reportes históricos** con la información disponible; no demuestra capacidad de anticipar la gravedad antes de que ocurra un siniestro. Además, los datos de vehículos pueden haberse obtenido al confirmar el reporte, por lo que antes de un uso operativo habría que verificar qué información existe realmente al momento de clasificar.

7. Limitaciones y alcance de los resultados

Conviene que quien lea los resultados tenga presentes los siguientes límites, que no invalidan el trabajo pero sí acotan lo que se puede afirmar con él:

- **Una sola partición aleatoria.** Los resultados no garantizan el mismo desempeño en años futuros, sobre todo por los cambios de captura del registro. La selección del modelo se hizo comparando en el conjunto de prueba, como exige el proyecto; lo más sólido sería elegir configuraciones con validación dentro de entrenamiento y reservar una prueba independiente.
- **Configuraciones iniciales.** La profundidad 8 y los 200 árboles se tomaron de los ejemplos de clase y no se buscaron hiperparámetros. Limitar la profundidad restringe la complejidad, pero no demuestra por sí solo que se evitó el sobreajuste.

- **Ponderación de clases.** *class_weight*="balanced" aumenta el peso de las clases minoritarias, pero puede aumentar las falsas alarmas, y no se evaluó una configuración sin ponderar para medir ese efecto.
- **Datos que dependen de cómo se registró.** Aun excluyendo las variables más ligadas al resultado, el medio de reporte (solo existe desde mayo de 2021), el año y el periodo pueden reflejar cambios del formulario más que características del siniestro.
- **Clasificación, no predicción.** El modelo asigna una gravedad a reportes que ya ocurrieron; no anticipa accidentes ni su gravedad, y sus datos de vehículos pueden ser posteriores a la ocurrencia.
- **Segmentos descriptivos.** Los grupos 1 y 5 son muy pequeños, los números de cluster no son una jerarquía de riesgo y el grupo 0 puede mezclar reportes con autos y reportes con valores imputados.

8. Recomendaciones para la Secretaría de Movilidad

Las siguientes recomendaciones se derivan de lo observado en los datos. Donde el análisis apunta a una explicación, se indica que es una hipótesis y no algo que el proyecto haya probado.

- **Priorizar la prevención en motociclistas y ciclistas.** Con bicicleta el 60,3% de los siniestros deja lesionados y con moto el 42,7%, frente al 11,5% cuando solo hay autos; los segmentos de bicicletas y motos de K-Means muestran lo mismo.
- **Seguir los fallecidos y los lesionados como indicadores propios.** Los fallecidos son el 0,9% de los reportes, pero se mantienen en unos 360-450 por año mientras el total de reportes cae a menos de la mitad; los promedios y el volumen de reportes esconden ese problema.
- **Mantener un formulario estable y completo.** Hoy no se puede saber, para todo el periodo, cuántos atropellos hubo ni si una intervención funcionó, porque el dato no existía antes. Volver obligatorios el tipo de vehículo y la clase de accidente es la mejora con más efecto.
- **Revisar los controles de fin de semana.** El domingo concentra los siniestros más graves (17,6% con víctimas y 1,4% con fallecidos). Las razones (por ejemplo, velocidad o consumo de alcohol) son hipótesis que este análisis no evalúa.
- **Mirar ejes viales completos y depurar las direcciones.** Las calles 10 y 25 aparecen tres veces cada una entre las 15 direcciones más frecuentes; antes de un análisis geográfico hay que separar los registros hechos en clínicas.
- **Usar los modelos solo como apoyo a la revisión.** Con una precisión de 10% en fallecidos, sirven para ordenar o estudiar reportes con supervisión humana, no para decidir sobre casos individuales.

9. Conclusiones y posibles mejoras

Conclusiones

- **Análisis:** la gravedad se asocia sobre todo con el actor vial. Bicicleta y moto concentran lesionados y fallecidos, y la segmentación lo confirma de forma independiente. Los fallecidos (0,9%) son la clase más escasa y la más costosa, por lo que no se deben priorizar solo por volumen de casos.
- **Limpieza:** casi todas las decisiones dependieron de entender por qué faltaba cada dato. Los faltantes siguen los cambios del formulario y el resultado del caso, por eso varias columnas conservan "SIN REGISTRO" y se excluyeron del modelado las variables más ligadas al registro del resultado.
- **Modelado:** los tres clasificadores superan la referencia (F1 macro 0,52-0,53 frente a 0,1994), pero con diferencias mínimas entre ellos y baja precisión en fallecidos. Son útiles para estudiar los registros, con las salvedades de las secciones 6 y 7.
- **Segmentación:** K-Means (k = 6) organiza los reportes por perfiles de vehículos; el grupo 0 concentra el 76% de los reportes.

Posibles mejoras

- **Evaluación más sólida:** seleccionar modelos con validación cruzada dentro de train y reservar el test para la evaluación final; medir el desempeño por año para ver el efecto de los cambios del registro (por ejemplo, entrenar con 2016-2022 y probar con 2023-2024); evaluar la estabilidad de los segmentos con otras muestras y semillas.

- **Hiperparámetros y ponderación:** buscar profundidad y número de árboles, y comparar con y sin *class_weight*, para estudiar si se puede equilibrar mejor la detección de casos minoritarios con las falsas alarmas. Probar también Gradient Boosting y ajustar el umbral de decisión para la clase fallecido.
- **Más variables:** hora del día, ubicación (barrio o coordenadas), estado de la vía, clima y velocidad. El modelo hoy no ve dónde ni a qué hora ocurrió el siniestro.
- **Calidad del registro:** mantener el mismo formulario durante años y volver obligatorios el tipo de vehículo y la clase de accidente. Es la mejora con más efecto, porque limita lo que cualquier modelo puede aprender de estos datos.
- **Más datos:** los casos con fallecido son 3.360; sumar fuentes (por ejemplo, medicina legal) estabilizaría las métricas de esa clase.

Anexo A. Glosario de métricas

Término	Qué significa
Accuracy	Proporción de reportes clasificados en su clase correcta. Puede engañar si una clase domina: aquí "Negativo" es el 66%.
Precision y Recall (de una clase)	Precision: de los reportes que el modelo asigna a la clase, cuántos pertenecen realmente a ella. Recall: de los que realmente son de la clase, cuántos detecta.
F1	Media armónica de Precision y Recall; resume ambos en un número.
Macro y ponderado	Macro: promedio simple entre las 4 clases, de modo que la clase escasa pesa igual. Ponderado: cada clase pesa según su número de casos.
AUC (uno contra todos)	Capacidad de separar una clase del resto: 0,5 equivale al azar y 1 es una separación perfecta.
Silhouette y Davies-Bouldin	Silhouette: cohesión y separación de los grupos, de -1 a 1 (más alto es mejor). Davies-Bouldin: similitud promedio entre grupos (más bajo es mejor).

Tabla 13. Términos usados en el informe.

Anexo B. Cómo reproducir el proyecto

El repositorio contiene los tres notebooks (*fase_a_eda*, *fase_b_limpieza* y *fase_c_modelos*), el archivo *datos_limpios.parquet*, este informe y la presentación. El CSV original (cerca de 27 MB) no está en el repositorio; debe descargarse y guardarse junto al README. Los pasos son:

- Copiar *.env.example* a *.env*; si el CSV está en otra carpeta, editar *RUTA_CSV* (ruta relativa a *entrega/*).
- Crear el entorno virtual con Python 3.10 o superior, activarlo e instalar las dependencias con *pip install -r requirements.txt*.
- Desde la carpeta *entrega/*, abrir Jupyter y ejecutar los notebooks en orden: A (gráficos e insights), B (genera *datos_limpios.parquet*) y C (métricas y comparación de modelos).
- La curva ROC y la gravedad por segmento de K-Means se calcularon aparte para este informe, con las mismas configuraciones y semilla de la Fase C (resultados idénticos en regresión logística y árbol; diferencia menor a 0,002 en Random Forest, atribuible al entorno).

> **Repositorio del proyecto en GitHub:** https://github.com/itspablito/DatosSinCiencia2y3
> Allí están los notebooks, datos_limpios.parquet, este informe y la presentación.