Siniestralidad vial en Santiago de Cali, 2016-2024

Análisis exploratorio, limpieza y modelado de la gravedad de los siniestros

Proyecto 2 y 3 · Ciencia de Datos · Grupo DatosSinCiencia · Octubre de 2026

1. Contexto del dataset y pregunta de negocio

El dataset reúne **370.996 reportes** de siniestros de tránsito recibidos por la Secretaría de Movilidad de Cali entre el 1 de enero de 2016 y el 2 de noviembre de 2024 (371.003 filas en el archivo original; se eliminaron 7 en la limpieza). Cada fila es un reporte con su fecha, dirección, clase de accidente, medio de reporte, número y tipo de vehículos implicados, y el resultado confirmado por el agente que acudió al sitio. El archivo viene en codificación Latin-1, separado por punto y coma, y marca los datos faltantes con un punto (".").

Variable objetivo: la gravedad del reporte, con cuatro clases ordenadas: *Negativo* (el agente acude y no se confirma un siniestro), *Solo daños*, *Con lesionado* y *Con fallecido*.

Pregunta de negocio: ¿qué características de un siniestro se asocian con su gravedad, para focalizar la prevención y priorizar la atención? Y como pregunta de modelado: ¿se puede estimar la gravedad de un reporte con los datos que se capturan hoy, y con qué nivel de confianza?

Clase de gravedad	Reportes	% del total
Negativo	246.107	66,3%
Solo daños	74.029	20,0%
Con lesionado	47.500	12,8%
Con fallecido	3.360	0,9%

El desbalance condiciona todo el trabajo posterior: la clase que más importa para la ciudad (fallecidos) es la menos frecuente. Por eso los modelos se evalúan con F1 macro y con el *recall* de la clase "Con fallecido", y no solo con el accuracy.

2. Resumen del análisis exploratorio (Fase A)

El análisis exploratorio incluyó histogramas, boxplots con detección de atípicos por IQR, mapas de faltantes, correlación de Pearson y Spearman, y gráficos de barras, líneas, barras apiladas, Pareto, violín y barras horizontales. Tres hallazgos resumen lo más importante para el negocio:

Hallazgo 1. Motociclistas y ciclistas concentran la gravedad

Cuando hay una bicicleta implicada, el **60,3%** de los siniestros deja lesionados y el **3,2%** fallecidos; con una moto, 42,7% y 1,7%; cuando solo hay autos o camionetas, 11,5% y 0,3%. Una moto hace el siniestro unas cinco veces más letal. La correlación de Spearman con la gravedad confirma el patrón: positiva con motos (+0,16) y negativa con autos (-0,23), porque el ocupante de un carro va más protegido.

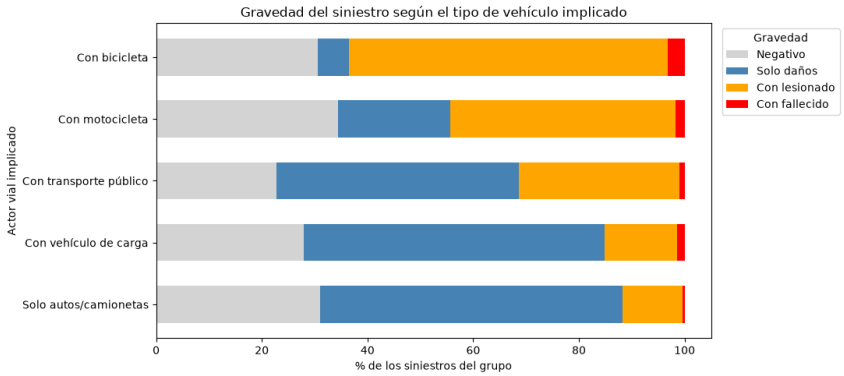


Figura 1. Gravedad según el actor vial implicado (Fase A, barras apiladas al 100%).

Hallazgo 2. Menos reportes no significa una ciudad más segura

El volumen mensual cae de unos 5.000 reportes a 2.500-3.000 desde marzo de 2020 y baja a unos 1.200 en 2024. Sin embargo, los siniestros con fallecido se mantienen casi constantes (entre 360 y 450 por año, cerca de uno por día), mientras que los de "solo daños" casi desaparecen desde 2023, cuando algunos reportes citan la Ley 2251 de 2022 para que los implicados resuelvan entre ellos los choques sin heridos. El indicador confiable a lo largo del tiempo es el de fallecidos.

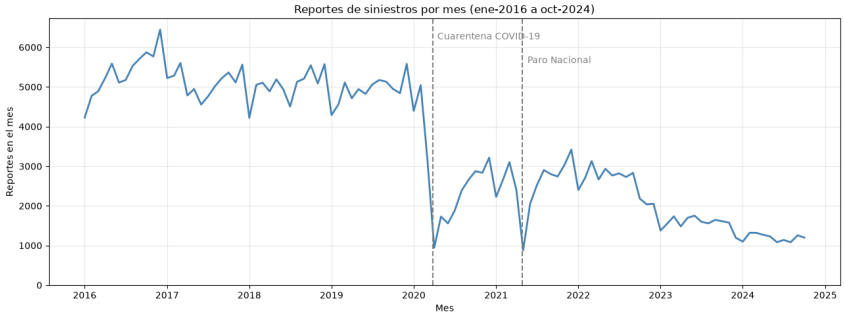


Figura 2. Reportes por mes, 2016-2024 (Fase A). Quiebre en marzo de 2020.

Hallazgo 3. La calidad del registro cambió con el tiempo y depende del resultado

La clase de accidente falta en el 87,7% de los reportes y el medio de reporte en el 77,7%, porque el formulario cambió varias veces (por ejemplo, el medio de reporte solo existe desde mayo de 2021). Además, el dato de vehículos falta en el **81% de los reportes "Negativo"** pero solo en el 16-19% de los siniestros con lesionados o solo daños. Esto tiene una consecuencia directa para el modelado: un modelo puede "adivinar" que un reporte es Negativo a partir del hueco y no del siniestro. En la Fase C se mide cuánto pesa este efecto. Otros hallazgos: el domingo es el día con menos reportes pero los más graves (1,4% con fallecidos, casi el doble que un jueves), y los atropellos y las caídas de ocupante dejan lesionados en cerca del 91% de los casos.

3. Técnicas de limpieza y normalización (Fase B)

El pipeline parte de las 371.003 filas originales y termina en **370.996 filas y 34 variables numéricas sin faltantes**. El orden importa: el split 80/20 estratificado por gravedad se hace *antes* de imputar, transformar y escalar, y todo valor aprendido de los datos (medianas, modas, parámetros de Yeo-Johnson, medias y desviaciones) se calcula solo con las filas de entrenamiento. Así se evita la fuga de datos hacia el conjunto de prueba.

Paso	Decisión	Justificación
Estructura	"." a NaN; se eliminan 1 fila vacía, 4 duplicados exactos, 2 filas sin gravedad y la columna repetida	Un duplicado cuenta doble un siniestro. La variable objetivo nunca se imputa: sería inventar la respuesta.

Paso	Decisión	Justificación
Texto	Mayúsculas, sin tildes y diccionario por columna: clase 14 a 6 variantes, medio 17 a 4, vehículos 54 tipos a 6 grupos	Misma categoría escrita de varias formas (CHOQUE / Choque). Evita decenas de columnas casi vacías.
Dirección	Se extrae el tipo de vía (calle, carrera, avenida...); clínicas como CENTRO MEDICO	Con 65 mil direcciones distintas, One-Hot sería inviable. En clínicas el caso se registra donde llega el lesionado.
Nulos numéricos	Mediana de train + indicador SIN_DATO_VEHICULOS	Conteos asimétricos: la mediana no se mueve con los choques múltiples y es un entero. El indicador marca qué filas se imputaron.
Nulos categóricos	"SIN REGISTRO" donde el campo no existía; moda de train donde faltan datos sueltos	Los faltantes dependen del año y del resultado: imputar la moda inventaría cerca de 290 mil valores de medio de reporte.
Outliers	IQR y Z-score. Se conservan todos; solo 2 valores imposibles (12 y 16 vehículos) pasan a NaN	Con IQR = 0 la regla IQR marca como atípico el 16% de los datos que son normales. Los choques múltiples son reales.
Sesgo	Yeo-Johnson (ajustado con train) en conteos con asimetría > 1	log(1+x) invertía el sesgo de NUM_VEHICULOS (+1,12 a -1,54); Yeo-Johnson lo dejó en 0,50.
Encoding	Ordinal: gravedad y periodo del registro. One-Hot con drop_first=True: clase, medio, vía y día de la semana	Solo las variables con orden natural reciben números ordenados; el One-Hot evita distancias inexistentes entre categorías.
Escalado	Z-score: conteos. Min-Max: año, mes, periodo	Rangos comparables para KNN, regresión logística y K-Means. RobustScaler no aplica porque el IQR es 0.

4. Modelos entrenados y comparación de desempeño (Fase C)

Se entrenaron tres clasificadores para estimar la gravedad registrada de cada reporte, usando la partición de la Fase B (296.796 reportes de train y 74.200 de test) y evaluando **solo en test**. Los modelos usan **20 variables**: los siete conteos de vehículos transformados, año, mes y periodo del registro, el medio de reporte y el día de la semana. Se excluyeron los identificadores, las dos representaciones del objetivo, la clase de accidente, el tipo de vía y el indicador de vehículos faltantes, porque pueden reflejar cómo se registró el resultado y no el siniestro (Hallazgo 3).

Los modelos son regresión logística, árbol de decisión (profundidad máxima 8) y Random Forest (200 árboles, profundidad máxima 8). Los tres usan *class_weight*="balanced" y semilla 42. Las configuraciones se fijaron antes de evaluar y no se hizo búsqueda de hiperparámetros. Como referencia, un modelo que siempre responde "Negativo" logra accuracy 0,6634 y F1 macro 0,1994.

Modelo	Accuracy	Precision macro	Recall macro	F1 macro	F1 ponderado	AUC macro*
Regresión logística	0,7243	0,5107	0,6369	0,5230	0,7444	0,815
Árbol de decisión	**0,7270**	0,5164	0,6394	0,5287	**0,7469**	0,836
Random Forest	0,7256	**0,5182**	**0,6448**	**0,5303**	0,7458	0,841

Tabla 1. Métricas en el conjunto de prueba (74.200 reportes); en negrita, el mejor valor de cada columna. *AUC uno contra todos, promediado entre las 4 clases, calculado para el informe con las mismas configuraciones.

Los tres modelos superan con claridad la referencia, pero quedan **muy cerca entre sí**: el accuracy está entre 0,7243 y 0,7270 y el F1 macro entre 0,5230 y 0,5303. Random Forest tiene el mayor F1 macro, pero su ventaja frente al árbol es de solo 0,0016, y el árbol tiene el mayor accuracy. Ningún modelo domina en todos los criterios.

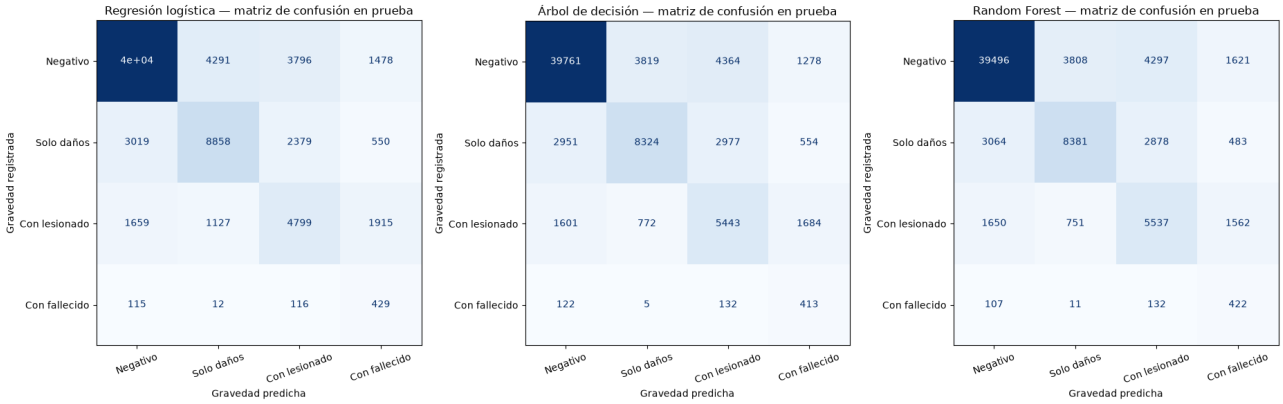


Figura 3. Matrices de confusión en test (número de reportes). Filas: gravedad registrada; columnas: gravedad predicha.

Las matrices muestran dónde se equivocan. "Negativo" se acierta en cerca del 80% de los casos. "Con lesionado" es la clase más difícil entre las frecuentes: el *recall* sube de 50,5% (regresión logística) a 57,3% (árbol) y 58,3% (Random Forest). En "Con fallecido" los errores van sobre todo hacia "Negativo" y "Con lesionado".

Desempeño en reportes con fallecido

Modelo	Precision	Recall	F1	Detectados (de 672)	Falsas alarmas
Regresión logística	0,0981	**0,6384**	0,1701	429	3.943
Árbol de decisión	**0,1051**	0,6146	**0,1795**	413	3.516
Random Forest	0,1032	0,6280	0,1773	422	3.666

Tabla 2. Clase "Con fallecido" en test.

Los modelos recuperan entre 61% y 64% de los reportes con fallecido, pero solo una de cada diez alertas de esa clase es correcta. Con Random Forest, 250 de los 672 casos fatales quedan clasificados en otra categoría y 3.666 reportes se marcan como fatales sin serlo. Con esa precisión, el modelo sirve para estudiar los registros, no como criterio único para decidir sobre un reporte individual.

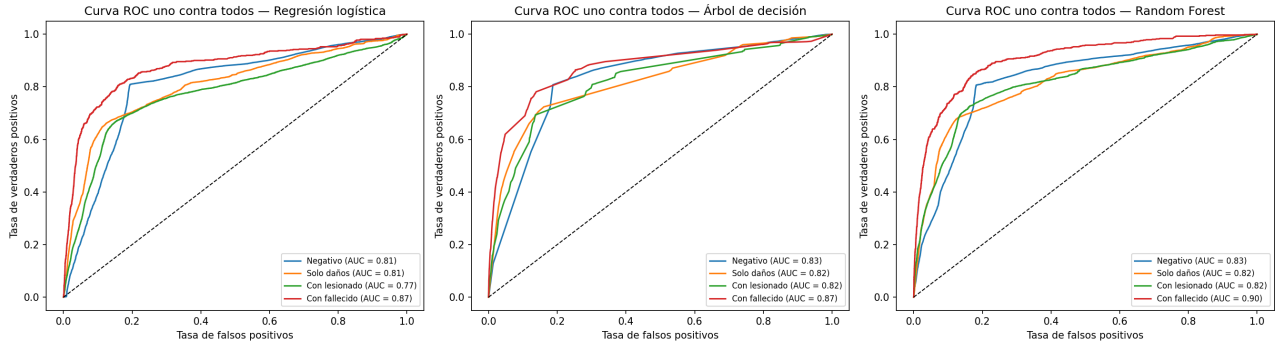


Figura 4. Curvas ROC uno contra todos en test (calculadas con las mismas configuraciones del notebook).

La curva ROC confirma que los modelos separan las clases mejor que el azar: el AUC de "Con fallecido" es de 0,87 a 0,90 según el modelo, mientras que las clases intermedias ("Solo daños" y "Con lesionado") quedan entre 0,77 y 0,82.

5. Segmentación no supervisada con K-Means

K-Means se aplicó sobre las mismas 20 variables, **sin usar la gravedad**. Se compararon de 2 a 10 grupos sobre una muestra reproducible de 10.000 reportes de entrenamiento (Silhouette sobre 2.000 de ellos). Con **k = 6** se obtuvo el mayor Silhouette (0,4334) y el menor Davies-Bouldin (0,6672); ambos criterios coinciden. El modelo final se ajustó con todo el train y los reportes de test se asignaron a los centros aprendidos: sobre 2.000 reportes de test, Silhouette 0,4261 y Davies-Bouldin 0,6779. Estas métricas describen la estructura de los grupos, no la capacidad de predecir gravedad.

Cluster	Train	Test	Perfil destacado	Negativo	Solo daños	Con lesionado	Con fallecido
0	225.919	56.486	Mayor valor relativo de autos; posible mezcla con registros imputados	77,1%	17,1%	5,1%	0,7%
1	1.050	251	Bicicletas	29,9%	6,4%	**61,0%**	**2,8%**
2	10.155	2.526	Transporte público	22,5%	45,3%	31,2%	1,0%
3	8.330	2.078	Vehículos de carga	28,3%	56,9%	13,4%	1,4%
4	50.543	12.660	Motocicletas	34,6%	21,5%	42,3%	1,5%
5	799	199	Otros vehículos	24,9%	51,2%	22,7%	1,3%

Tabla 3. Tamaño y perfil de cada segmento. Las últimas cuatro columnas (porcentaje de cada gravedad dentro del cluster, en train) se calcularon para el informe; el notebook no las incluye.

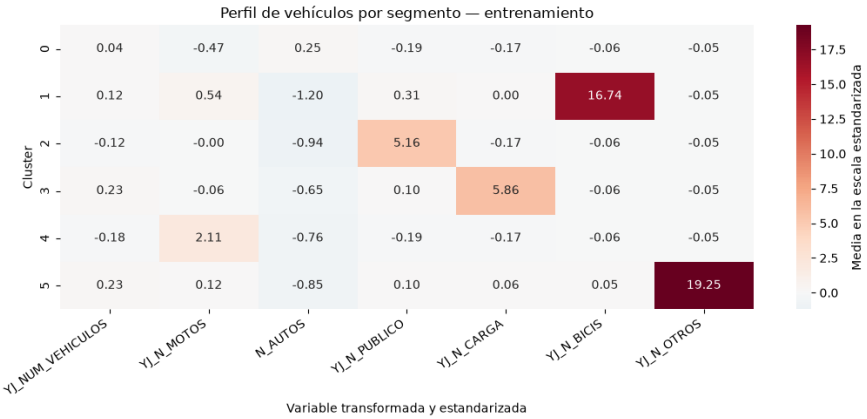


Figura 5. Perfil de vehículos por segmento (medias en escala estandarizada, entrenamiento).

Los seis segmentos se distinguen sobre todo por el actor vial: el grupo 4 destaca en motocicletas, el 2 en transporte público, el 3 en carga, el 1 en bicicletas y el 5 en otros vehículos. El grupo 0 concentra cerca del 76% de los reportes. Al cruzar los segmentos con la gravedad se ve lo mismo que en el análisis exploratorio: los grupos de bicicletas (61,0% con lesionados) y motos (42,3%) tienen mucha más gravedad que el grupo 0 (5,1%). Es una descripción, no una prueba de que el segmento cause el resultado, y los grupos 1 y 5 son pequeños (799 y 1.050 reportes de train), por lo que se leen con cautela.

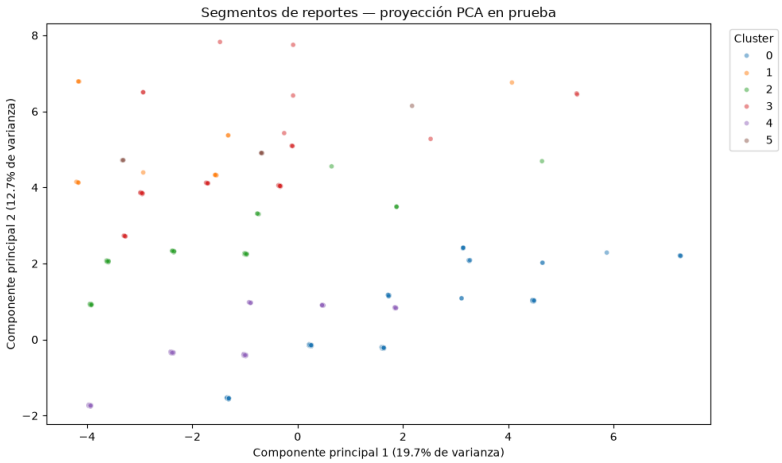


Figura 6. Segmentos K-Means en 2 componentes principales (5.000 reportes de test; 32,35% de la varianza).

La proyección PCA conserva solo el 32,35% de la varianza, y como casi todas las variables son discretas, muchos puntos se superponen: sirve para visualizar, no para comparar tamaños de grupos. Los segmentos pueden reflejar también diferencias de captura entre periodos, y sus números son identificadores, no niveles de riesgo.

6. Modelo elegido y justificación

Modelo final: Random Forest, entre las configuraciones evaluadas. Se eligió porque tiene el mayor F1 macro (0,5303), el criterio principal por dar el mismo peso a cada clase en un problema donde "Con fallecido" es solo el 0,91% de los reportes. También tiene la mayor Precision macro, el mayor Recall macro y el mayor F1 para "Con lesionado" (0,4956). La decisión tiene límites claros:

- La ventaja sobre el árbol es de solo **0,0016** de F1 macro y viene de una sola partición, así que no demuestra superioridad consistente. Si el criterio fuera la simplicidad y la lectura de reglas, el **árbol de decisión** es una alternativa razonable: tiene el mayor accuracy (0,7270) y el mayor F1 para fallecidos (0,1795).
- La **regresión logística** es la más simple de explicar y alcanza el mayor *recall* en fallecidos (63,8%), a costa de más falsas alarmas (3.943).
- Random Forest no es el mejor en fallecidos y su precisión en esa clase es de 10,3%: es un resultado experimental del proyecto, no una herramienta para decidir sobre casos individuales.

El ejercicio **clasifica reportes históricos** con la información disponible; no demuestra capacidad de anticipar la gravedad antes de que ocurra un siniestro. Además, los datos de vehículos pueden haberse obtenido al confirmar el reporte, por lo que antes de un uso operativo habría que verificar qué información existe realmente al momento de clasificar.

7. Conclusiones y posibles mejoras

Conclusiones

- **Análisis:** la gravedad se asocia sobre todo con el actor vial. Bicicleta y moto concentran lesionados y fallecidos, y la segmentación lo confirma de forma independiente. Los fallecidos (0,9%) son la clase más escasa y la más costosa, por lo que no se deben priorizar solo por volumen de casos.
- **Limpieza:** casi todas las decisiones dependieron de entender por qué faltaba cada dato. Los faltantes siguen los cambios del formulario y el resultado del caso, por eso varias columnas conservan "SIN REGISTRO" y se excluyeron del modelado las variables más ligadas al registro del resultado.
- **Modelado:** los tres clasificadores superan la referencia (F1 macro 0,52-0,53 frente a 0,1994), pero con diferencias mínimas entre ellos y baja precisión en fallecidos. Son útiles para estudiar los registros, con las salvedades de la sección 6.

- **Segmentación:** K-Means (k = 6) organiza los reportes por perfiles de vehículos; el grupo 0 concentra el 76% de los reportes.

Posibles mejoras

- **Evaluación más sólida:** seleccionar modelos con validación cruzada dentro de train y reservar el test para la evaluación final; medir el desempeño por año para ver el efecto de los cambios del registro; evaluar la estabilidad de los segmentos con otras muestras y semillas.
- **Hiperparámetros y ponderación:** buscar profundidad y número de árboles, y comparar con y sin *class_weight*, para estudiar si se puede equilibrar mejor la detección de casos minoritarios con las falsas alarmas. Probar también Gradient Boosting y ajustar el umbral de decisión para la clase fallecido.
- **Más variables:** hora del día, ubicación (barrio o coordenadas), estado de la vía, clima y velocidad. El modelo hoy no ve dónde ni a qué hora ocurrió el siniestro.
- **Calidad del registro:** mantener el mismo formulario durante años y volver obligatorios el tipo de vehículo y la clase de accidente. Es la mejora con más efecto, porque limita lo que cualquier modelo puede aprender de estos datos.
- **Más datos:** los casos con fallecido son 3.360; sumar fuentes (por ejemplo, medicina legal) estabilizaría las métricas de esa clase.