INTRODUCCIÓN A LA CIENCIA DE LOS DATOS · **PROYECTO 2 Y 3**

Siniestralidad vial en Santiago de Cali, 2016–2024

Informe final: análisis exploratorio, limpieza y normalización, modelos de clasificación y segmentación de 370.996 reportes de siniestros de tránsito.

GRUPO DATOSSINCIENCIA

INTEGRANTES	CÓDIGO
Juan José Guzmán Camacho	**2380403**
Juan Pablo Rodríguez Gutiérrez	**2380422**
Natalia Martínez Castañeda	**2380414**
Jesus Ediber Arenas Guzmán	**2266066**
Juan José Wallens Serna	**2380556**

PROFESOR
Héctor Fabio Ocampo Arbeláez

ASIGNATURA
Introducción a la Ciencia de los Datos

REPOSITORIO
https://github.com/itspablito/DatosSinCiencia2y3

FUENTE DE DATOS
Secretaría de Movilidad de Cali · `siniestralidad_2016_2024.csv`

Resumen ejecutivo

Este informe recoge las cuatro fases del Proyecto 2 y 3 sobre los reportes de siniestros de tránsito recibidos por la Secretaría de Movilidad de Cali entre el 1 de enero de 2016 y el 2 de noviembre de 2024. La pregunta de negocio es **qué características de un siniestro se asocian con su gravedad** (solo daños, con lesionados o con fallecidos) para focalizar la prevención y priorizar la atención; la pregunta de modelado es si esa gravedad se puede estimar con los datos que hoy se capturan y con qué confianza.

370.996
reportes analizados tras la limpieza (371.003 en el archivo original)

66,3 %
de los reportes son "Negativo": el agente acude y no se confirma un siniestro

3.360
reportes con fallecido (0,9 %): cerca de uno por día durante ocho años

60 %
de los siniestros con bicicleta deja lesionados; con moto, 43 %; solo autos, 11,5 %

87,7 %
de faltantes en la clase de accidente: el campo solo está completo en 2024

0 %
de faltantes al final de la Fase B, con 34 variables predictoras listas para modelar

0,530
F1 macro del mejor clasificador (Random Forest), frente a 0,199 de la referencia

k = 6
segmentos de K-Means, uno por actor vial; el grupo de autos reúne el 76 %

Los cinco hallazgos que sostienen el informe

1. **Motociclistas y ciclistas concentran la gravedad**
   Con una bicicleta implicada el 60,3 % de los siniestros deja lesionados y el 3,2 % fallecidos; con una moto, 42,7 % y 1,7 %; cuando solo chocan autos o camionetas, 11,5 % y 0,3 %. Una moto hace el siniestro cinco veces más letal. La segmentación no supervisada llega a la misma conclusión por otro camino.

2. **Dos de cada tres reportes no terminan en un siniestro confirmado**
   El 66,3 % de los reportes es "Negativo" y solo el 0,9 % tiene fallecidos. La clase que más importa para la ciudad es la menos frecuente, por lo que los modelos se evalúan con F1 macro y con el recall de "Con fallecido", no con el acierto global.

3. **Menos reportes no significa una ciudad más segura**
   El volumen mensual cae de ≈5.000 a ≈2.500 en marzo de 2020 y a ≈1.200 en 2024; los "solo daños" casi desaparecen desde 2023 (Ley 2251 de 2022). Los fallecidos, en cambio, se mantienen entre 362 y 451 por año de 2016 a 2023. El indicador confiable para seguir el problema son los fallecidos.

4. **Los huecos del registro también informan, y pueden engañar a un modelo**
   Los faltantes dependen del año (el formulario cambió) y del resultado: el dato de vehículos falta en el 81 % de los "Negativo" y solo en el 16–19 % de los siniestros con víctimas o daños. Un modelo podría "adivinar" el resultado a partir del hueco; por eso varias variables se excluyeron del modelado.

5. **Los modelos superan la referencia, pero con límites claros**
   Regresión logística, árbol de decisión y Random Forest alcanzan F1 macro de 0,523 a 0,530 (referencia: 0,199) y recuperan el 61–64 % de los reportes con fallecido, pero solo una de cada diez alertas de esa clase es correcta. Sirven para estudiar los registros con supervisión humana, no para decidir sobre casos individuales.

Contenido

1 Contexto del dataset y pregunta de negocio

2 Fase A · Análisis exploratorio

2.1 Perfil y calidad de los datos · 2.2 Estadísticos descriptivos · 2.3 Distribuciones y atípicos · 2.4 Correlación · 2.5 Hallazgos principales · 2.6 Hallazgos de apoyo · 2.7 Resumen de la fase

3 Fase B · Limpieza y normalización

3.1 Pipeline · 3.2 Diagnóstico · 3.3 Limpieza estructural y texto · 3.4 Variables derivadas · 3.5 Outliers · 3.6 Split · 3.7 Nulos · 3.8 Transformación · 3.9 Encoding · 3.10 Escalado · 3.11 Resultado

4 Fase C · Modelos de clasificación

4.1 Variables y configuración · 4.2 Métricas globales · 4.3 Desempeño por clase · 4.4 Matrices de confusión · 4.5 La clase “Con fallecido” · 4.6 Curvas ROC

5 Fase C · Segmentación con K-Means

6 Modelo elegido y justificación

7 Limitaciones y alcance

8 Recomendaciones para la Secretaría de Movilidad

9 Conclusiones y posibles mejoras

A Glosario de métricas

B Cómo reproducir el proyecto

C Inventario de gráficos de los notebooks

1 Contexto del dataset y pregunta de negocio

El archivo `siniestralidad_2016_2024.csv` tiene **371.003 filas y 10 columnas**, una por cada reporte de siniestro de tránsito recibido por la Secretaría de Movilidad de Cali. Viene en codificación Latin-1, separado por punto y coma, con todas las columnas como texto y con los datos faltantes marcados con un punto (`"."`) en lugar de celdas vacías. Cada fila indica la fecha, el resultado confirmado por el agente que acudió (`Tipo confirmado`), un detalle de ese resultado, la dirección, la clase de accidente, el medio por el que se reportó, el número de vehículos y la lista de vehículos implicados. Este trabajo continúa el Proyecto 1, que exploró y modeló dimensionalmente el mismo dataset.

Columna original	Tipo de variable	Contenido
`Código`	Identificador	Un código por reporte (370.998 valores distintos)
`Fecha`	Fecha	Día del reporte, formato `d/mm/aaaa`
`Tipo confirmado`	**Categórica ordinal (objetivo)**	Negativo < Solo daños < Con lesionado < Con fallecido
`Tipo confirmado.1`	Categórica nominal	Detalle del resultado (“Falsa alarma”, “No quiere intervención”, “Inspección a cadáver”…)
`Dirección reporte`	Texto libre	Cruce de calles o lugar; 65.335 valores distintos
`Tipo clase de accidente` (×2)	Categórica nominal	Choque, atropello, volcamiento, caída de ocupante, otro; la segunda columna es una copia exacta
`Medio de reporte`	Categórica nominal	Línea 127, CAD 123, radio, redes sociales…
`Numero vehículos`	Numérica discreta	Única variable numérica original
`Tipo de vehículos implicados`	Categórica (lista)	Ej.: `AUTOMOVIL,MOTOCICLETA`; 54 tipos distintos

Tabla 1. Columnas del archivo original y su clasificación (Fase A, Sección 1).

Variable objetivo. La gravedad del reporte, con cuatro clases ordenadas: *Negativo* (el agente acude y no se confirma un siniestro que requiera intervención), *Solo daños*, *Con lesionado* y *Con fallecido*. Su desbalance condiciona todo el trabajo posterior.

Clase de gravedad	Reportes	% del total	Qué significa
Negativo	246.107	66,3 %	Falsa alarma, los implicados no quieren intervención o ya se retiraron
Solo daños	74.029	20,0 %	Siniestro confirmado sin personas lesionadas
Con lesionado	47.500	12,8 %	Al menos una persona lesionada
Con fallecido	3.360	0,9 %	Al menos un fallecido; incluye 453 casos “foráneo” (residente fuera de Cali)

Tabla 2. Distribución de la variable objetivo en los 370.996 reportes que quedan tras la limpieza.

PREGUNTA DE NEGOCIO

¿Qué características de un siniestro se asocian con su gravedad, para focalizar la prevención y priorizar la atención?

PREGUNTA DE MODELADO

¿Se puede estimar la gravedad de un reporte con los datos que se capturan hoy, y con qué nivel de confianza? ¿Qué perfiles de reportes existen sin mirar la gravedad?

2 Fase A · Análisis exploratorio

El objetivo de la fase fue caracterizar el dataset con los estadísticos y gráficos adecuados a cada tipo de variable, y traducir lo que revelan los datos a hallazgos de negocio. El notebook `fase_a_eda.ipynb` contiene 15 gráficos (mapa de faltantes, histogramas, boxplots, matrices de correlación, barras, líneas, barras apiladas, Pareto, violín y barras horizontales), cada uno con su interpretación. Antes de calcular nada se clasificaron las variables (Tabla 1), siguiendo la regla de la clase 4.

2.1 Perfil y calidad de los datos

El perfil inicial mostró que todas las columnas llegan como texto, que los faltantes son puntos que pandas contaría como datos válidos, que hay dos columnas repetidas, texto inconsistente (`Solo daños` / `Solo Daños`, `CHOQUE` / `Choque`), tildes dañadas por la codificación (`Ca?da`, `TELEF?NICO`), 4 filas duplicadas y una fila vacía al final. Para explorar se hizo solo la preparación mínima: `"."` → `NaN`, retiro de la fila vacía y los duplicados, unificación de la gravedad en cuatro clases y creación de variables de fecha y de conteo de vehículos por tipo. La limpieza completa quedó para la Fase B.

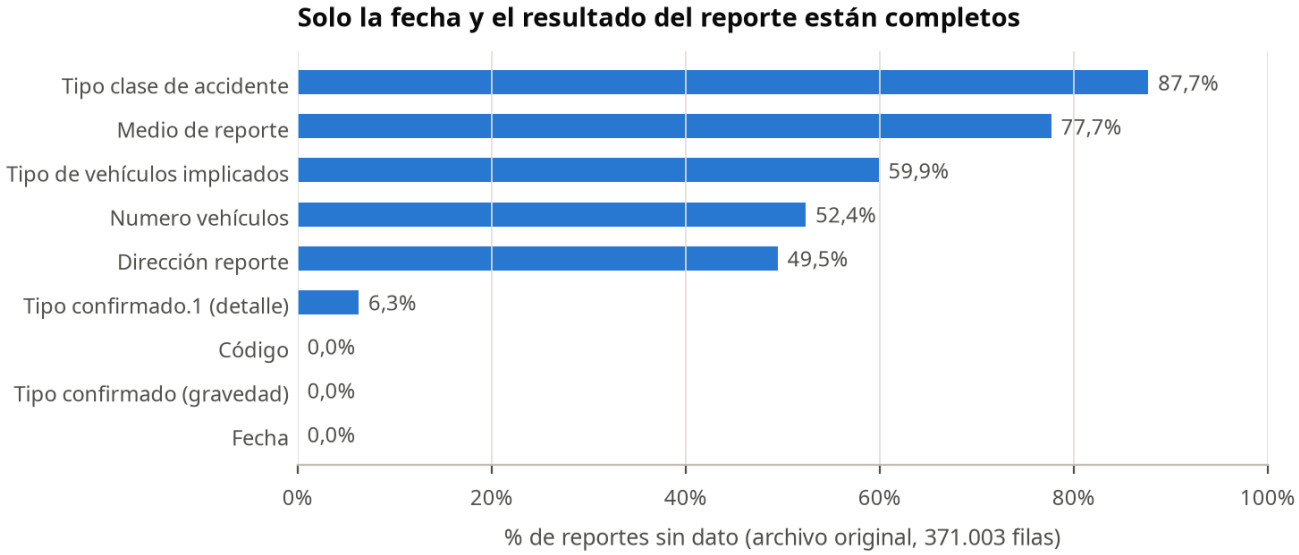


Figura 1. Porcentaje de valores faltantes por columna en el archivo original. Solo la fecha, el código y el resultado del reporte están completos; los campos que describen *cómo* ocurrió el siniestro son los menos diligenciados.

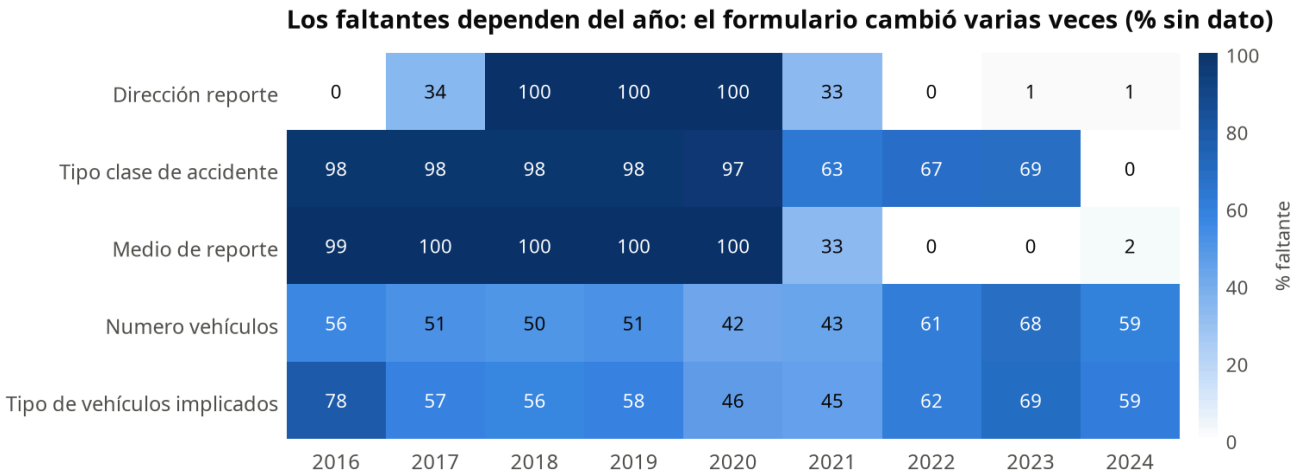


Figura 2. Porcentaje de faltantes por columna y año. La dirección no se registró entre 2018 y 2020, el medio de reporte solo existe desde mayo de 2021 y la clase de accidente solo está casi completa en 2024: los huecos no son aleatorios, siguen los cambios del formulario de captura.

PARA EL NEGOCIO

Con este sistema la Secretaría no puede responder, para todo el periodo, preguntas básicas como "¿cuántos atropellos hubo?" ni saber si los siniestros en un punto de la ciudad subieron o bajaron entre años. Mantener el mismo formulario año tras año es requisito para evaluar cualquier política de seguridad vial.

PARA EL PROYECTO

Los faltantes dependen del año, así que no se imputan con un solo valor para todo el rango: en la Fase B cada columna recibe una estrategia según el periodo en que el campo existía.

2.2 Estadísticos descriptivos

El dataset tiene una sola variable numérica original; las demás se construyeron a partir de la fecha y de la lista de vehículos. Para cada variable se eligió la medida según su forma: media si es simétrica, mediana si es asimétrica o tiene atípicos, moda si es categórica. Se calcularon también el coeficiente de variación y la asimetría (si |asimetría| > 1 la mediana describe mejor los datos).

Variable	Media	Mediana	Desv. est.	Máximo	IQR	CV (%)	Asimetría	Curtosis
Número de vehículos	1,95	2	0,44	16	0	22,5	1,23	20,3
Motocicletas	0,52	0	0,62	5	1	118,1	0,80	−0,07
Autos y camionetas	1,16	1	0,79	5	1	67,9	0,13	−0,33
Transporte público	0,09	0	0,31	5	0	325,4	3,25	10,5
Vehículos de carga	0,07	0	0,27	3	0	369,7	3,68	13,4
Bicicletas	0,01	0	0,09	2	0	1.067,8	10,80	119,1
Gravedad (0 a 3)	0,48	0	0,75	3	1	155,0	1,30	0,48

Tabla 3. Estadísticos descriptivos de las variables numéricas (Fase A, antes de imputar; conteos de vehículos solo en los reportes con dato). Modas de las categóricas: gravedad "Negativo", clase de accidente "Choque", medio de reporte "Telefónico 127".

Lectura. El siniestro típico en Cali es **un choque entre dos vehículos** (media ≈ mediana ≈ 2), en cuatro de cada cinco casos con un automóvil y en casi la mitad con una moto. Buses, camiones y bicicletas aparecen pocas veces (mediana 0) y son muy asimétricos (asimetría 3,3 a 10,8), pero eso no los hace menos importantes: cuando hay una bicicleta o una moto el siniestro es mucho más grave (Sección 2.5). La Secretaría no debería fijar sus prioridades solo por el volumen de casos de cada tipo de vehículo.

2.3 Distribuciones y detección de atípicos

Los histogramas de los conteos usan eje logarítmico para que se vean las colas. Casi todos los siniestros involucran 1 o 2 vehículos y los choques múltiples (5 o más) son excepcionales. Los reportes por día no forman una sola campana sino varias "montañas" (alrededor de 50, 100 y 180 reportes diarios), señal de que la ciudad pasó por periodos con volúmenes muy distintos (2016–2019, 2020–2022 y 2023–2024); por eso la media de 115 reportes diarios no describe un "día típico" de ningún periodo.

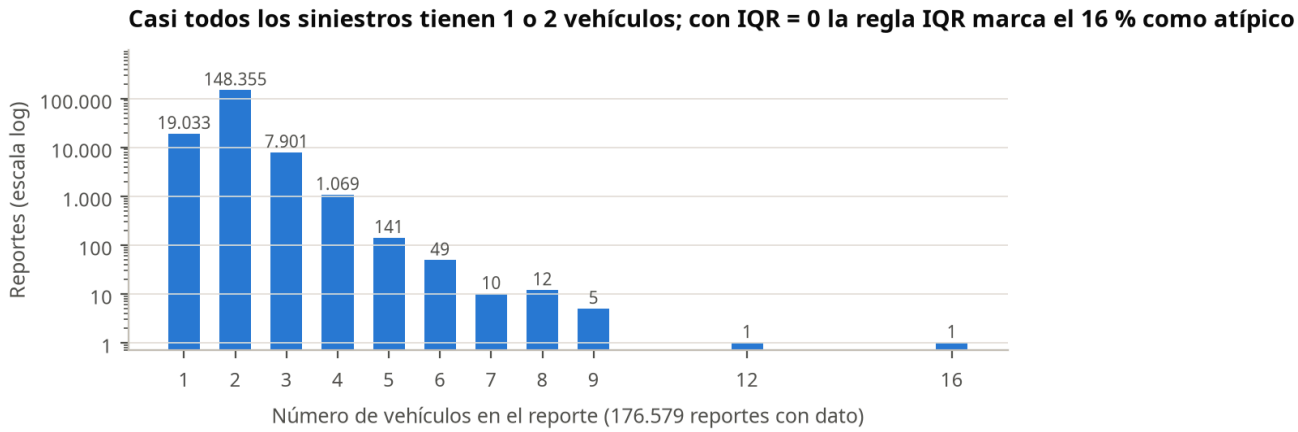


Figura 3. Reportes según el número de vehículos implicados (escala logarítmica). Como Q1 = Q3 = 2, el rango intercuartílico es 0 y la regla de Tukey marca como atípico cualquier valor distinto de 2.

Variable	Q1	Q3	IQR	Límites	Atípicos IQR	%	Lectura
Número de vehículos	2	2	0	[2, 2]	28.222	16,0	≈19.000 con un solo vehículo y ≈9.200 con tres o más
Motocicletas	0	1	1	[−1,5; 2,5]	238	0,2	Siniestros con 3 o más motos
Autos y camionetas	1	2	1	[−0,5; 3,5]	420	0,3	Choques en cadena de 4 o más autos
Transporte público	0	0	0	[0, 0]	13.411	9,0	Todo siniestro con un bus queda marcado
Vehículos de carga	0	0	0	[0, 0]	10.483	7,1	Todo siniestro con un camión queda marcado
Bicicletas	0	0	0	[0, 0]	1.307	0,9	Todo siniestro con bicicleta queda marcado

Tabla 4. Detección de atípicos con la regla IQR (Q1 − 1,5·IQR; Q3 + 1,5·IQR) sobre los conteos de vehículos.

> **Decisión.** La regla IQR marca como “atípicos” a 28.222 siniestros (16 %) que no son errores de captura sino justamente los tipos de siniestro más graves para la ciudad: atropellos, volcamientos y caídas de ocupante con un solo vehículo, y choques en cadena. Borrarlos dejaría a la Secretaría sin información sobre peatones y choques múltiples. Se conservan todos; solo los casos con 9 o más vehículos se revisan en la Fase B. Los días con 1 a 5 reportes (30 de abril al 4 de mayo de 2021) coinciden con el Paro Nacional, cuando el sistema operó parcialmente: son atípicos reales del registro y también se conservan.

2.4 Correlación entre variables numéricas

Se calcularon Pearson (relación lineal) y Spearman (relación monótona por rangos). Como las variables son conteos sesgados y una ordinal, **Spearman es la referencia**; ambos métodos dan el mismo patrón. Correlación no implica causalidad.

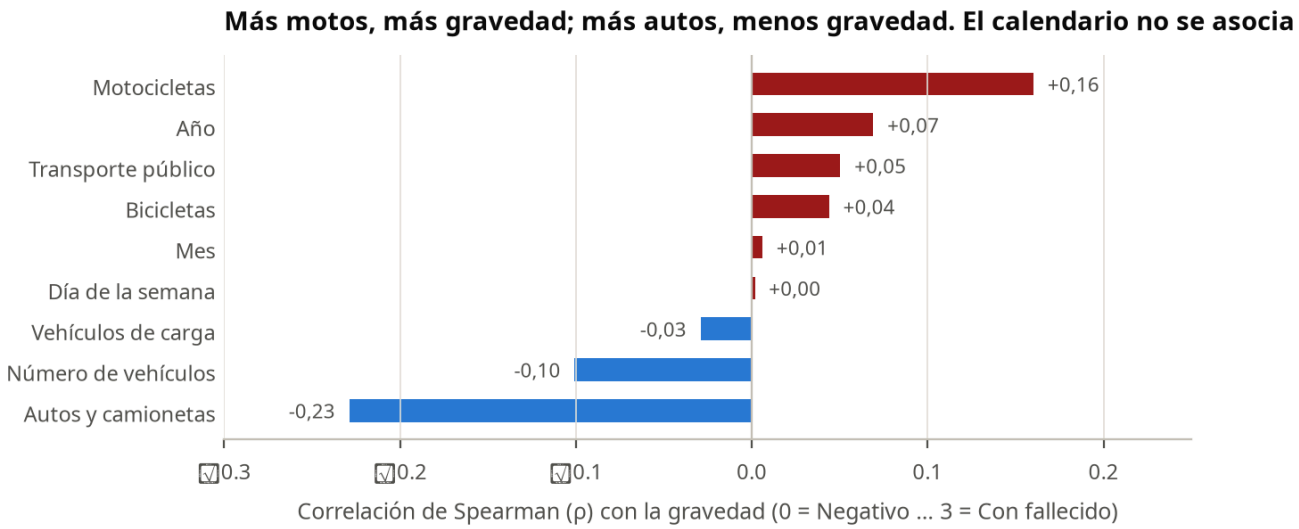


Figura 4. Correlación de Spearman de cada variable con la gravedad. Las correlaciones son débiles pero coherentes: positiva con motos (+0,16) y negativa con autos (−0,23). Las variables de calendario están en cero. Entre motos y autos la correlación es ≈ −0,6: comparten información.

PARA EL NEGOCIO

El tipo de vehículo es lo que más se asocia con la gravedad: el ocupante de un carro va protegido y el motociclista no. El mes o el día de la semana, por sí solos, no cambian la gravedad esperada.

PARA EL PROYECTO

Las variables de vehículos son las candidatas más fuertes para los modelos, pero su disponibilidad depende del resultado del caso (Hallazgo 4). El día de la semana entra como categórica (One-Hot), no como número.

2.5 Hallazgos principales

Hallazgo 1 · Motociclistas y ciclistas concentran la gravedad

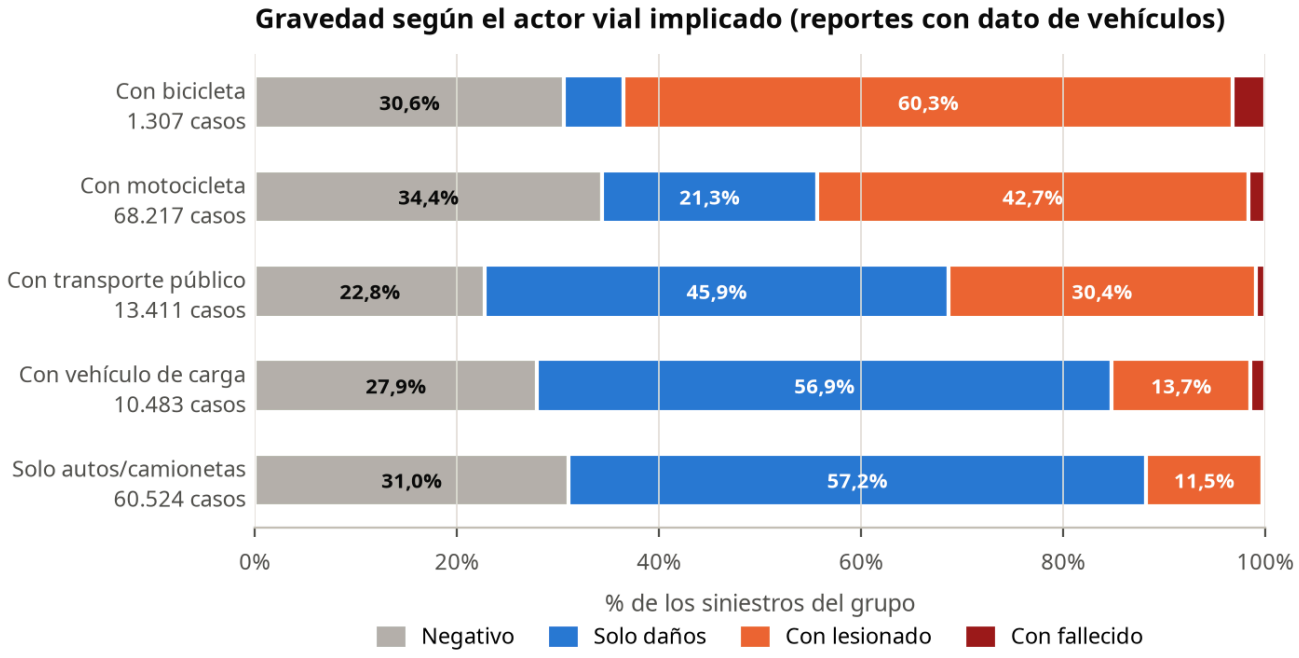


Figura 5. Gravedad del siniestro según el actor vial implicado, en los 148.782 reportes con dato de vehículos (barras apiladas al 100 %). Un reporte puede pertenecer a más de un grupo; “Solo autos/camionetas” excluye cualquier otro actor.

Siniestros que involucran…	Casos	Negativo	Solo daños	Con lesionado	Con fallecido
Bicicleta	1.307	30,6 %	5,9 %	**60,3 %**	**3,2 %**
Motocicleta	68.217	34,4 %	21,3 %	**42,7 %**	**1,7 %**
Transporte público	13.411	22,8 %	45,9 %	30,4 %	1,0 %
Vehículo de carga	10.483	27,9 %	56,9 %	13,7 %	1,5 %
Solo autos/camionetas	60.524	31,0 %	57,2 %	11,5 %	0,3 %

Tabla 5. Gravedad según el actor vial implicado (Fase A, Sección 8.3).

El riesgo depende de quién va expuesto. Una moto hace el siniestro **cinco veces más letal** que un choque entre carros, y las motos están en el 46 % de los siniestros con información de vehículos. El transporte público también sobresale (30 % con lesionados), por pasajeros que se golpean o caen dentro del bus. Automóviles y motocicletas suman el 84 % de todos los vehículos implicados (Figura 6).

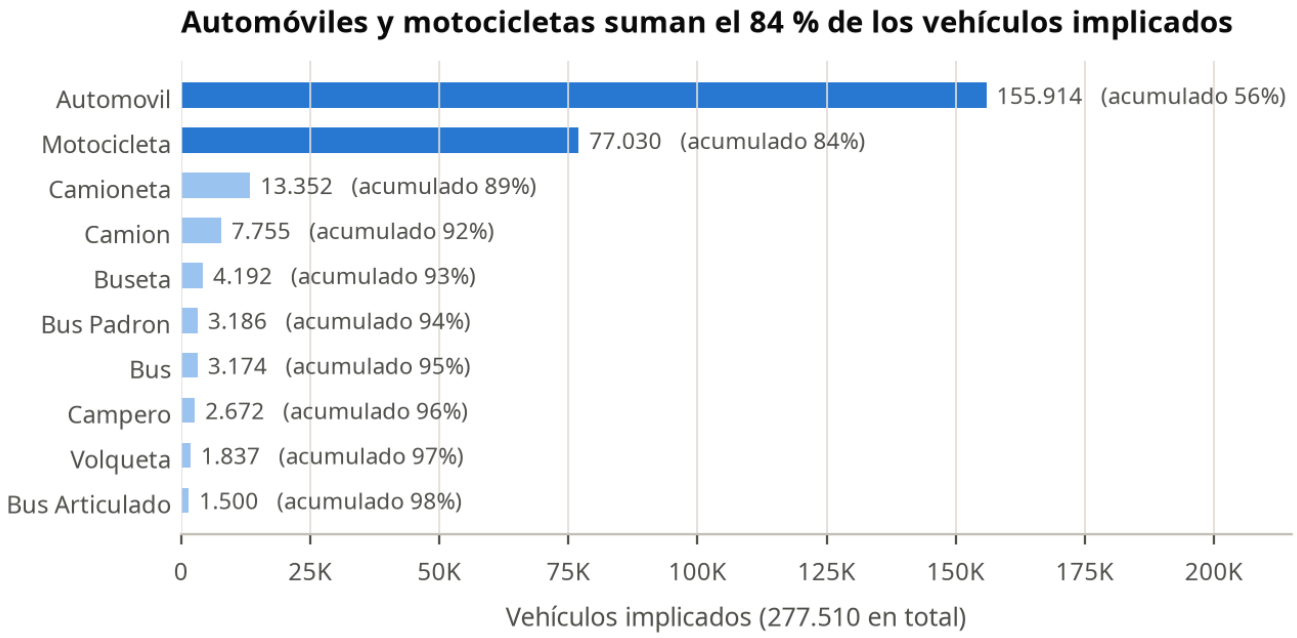


Figura 6. Los diez tipos de vehículo más implicados y su porcentaje acumulado. Con solo dos tipos se explica la gran mayoría de la siniestralidad (principio 80/20), lo que justifica agrupar los 54 tipos en seis categorías en la Fase B.

PARA EL NEGOCIO

Las campañas, la infraestructura (carriles, cruces) y los controles con mayor impacto en vidas son los dirigidos a motociclistas y ciclistas: es el grupo donde la prevención salvaría más vidas.

PARA EL PROYECTO

El tipo de vehículo explica la gravedad *entre siniestros confirmados*. Pero el dato falta en el 81 % de los "Negativo" y solo en el 16–19 % de los siniestros con daños o lesionados (55 % de los fallecidos), porque se registra al confirmar el caso: hay riesgo de fuga de datos si se usa para predecir "Negativo".

Hallazgo 2 · Dos de cada tres reportes no terminan en un siniestro confirmado

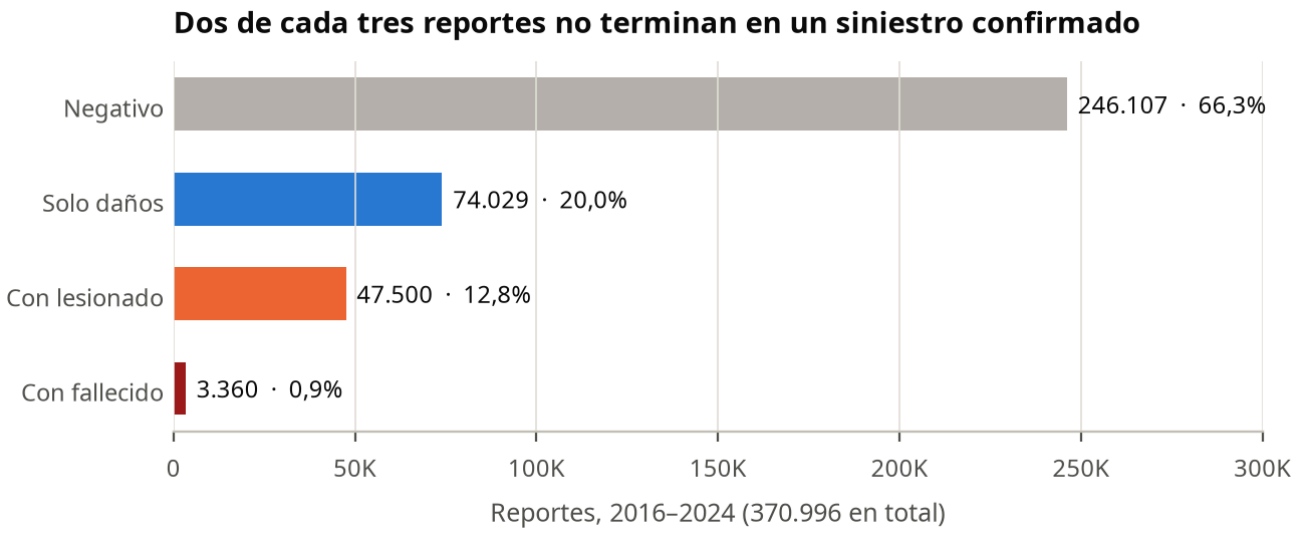


Figura 7. Número de reportes según su gravedad, 2016–2024. Dentro de los 246.107 "Negativo", el detalle del resultado indica 20.663 casos "No quiere intervención" y 3.773 "Falsa alarma".

El 66,3 % de los reportes es "Negativo": el agente acude pero no se confirma un siniestro que requiera intervención. Es un costo operativo enorme para la Secretaría. En el otro extremo, 3.360 reportes (0,9 %) tuvieron fallecidos: **la clase que más importa y la más escasa**, aunque son 3.360 muertes en ocho años, cerca de una por día.

PARA EL NEGOCIO

La mayor parte del esfuerzo de atención se va en reportes que no requieren actuación, y el problema más costoso es el menos frecuente: un indicador basado en el total de reportes o en promedios lo esconde. Los fallecidos y lesionados deben seguirse como indicador propio.

PARA EL PROYECTO

La variable objetivo está muy desbalanceada. Un modelo que diga siempre "Negativo" acierta el 66 % sin servir para nada; por eso el split es estratificado y los modelos se comparan con F1 macro y con recall y precision por clase, no solo con accuracy.

Hallazgo 3 · El registro cambió con el tiempo: menos reportes no es una ciudad más segura

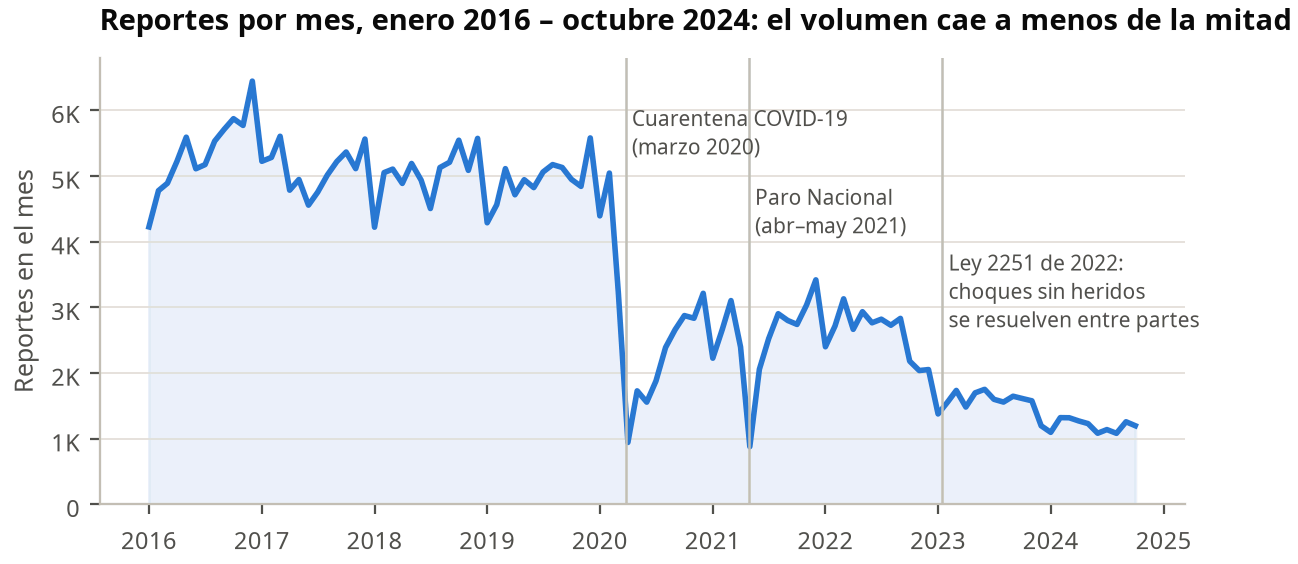


Figura 8. Reportes por mes, enero de 2016 a octubre de 2024 (noviembre de 2024 solo tiene dos días). El quiebre de marzo de 2020 nunca se recupera, aunque la movilidad de la ciudad sí lo hizo.

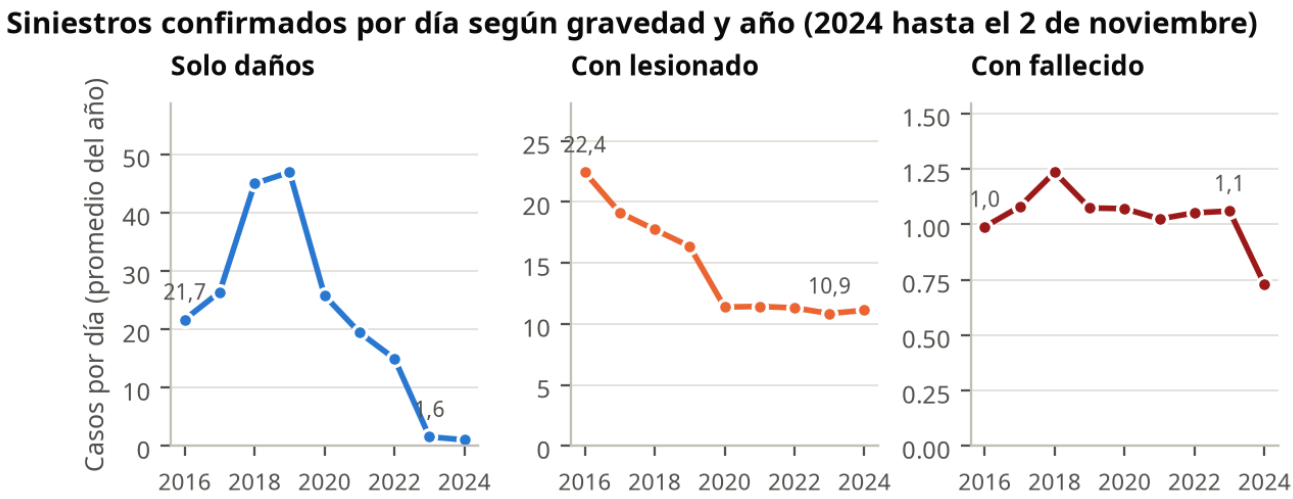


Figura 9. Promedio diario de siniestros confirmados por gravedad y año. Los "solo daños" pasan de 47 diarios en 2019 a 1–2 en 2023–2024; los fallecidos se mantienen cerca de uno por día hasta 2023.

Año	2016	2017	2018	2019	2020	2021	2022	2023	2024*
Solo daños	7.936	9.637	16.428	17.142	9.437	7.101	5.464	566	318
Con lesionado	8.215	6.985	6.475	5.974	4.167	4.175	4.131	3.963	3.415
Con fallecido	362	394	451	392	392	374	384	387	224

Tabla 6. Siniestros confirmados por año y gravedad. *2024 llega hasta el 2 de noviembre.

- El volumen cae de ≈5.000 a ≈2.500–3.000 reportes al mes en marzo de 2020 (cuarentena por COVID-19) y no regresa al nivel anterior; desde finales de 2022 vuelve a bajar hasta ≈1.200 al mes en 2024. El volumen diario pasó de una mediana de ≈170 a ≈85 reportes.
- Los "solo daños" se desploman desde 2023 (de 5.464 en 2022 a 566). Algunos reportes citan la **Ley 2251 de 2022** para que los implicados resuelvan entre ellos los choques sin heridos, lo que explicaría por qué esos casos dejaron de llegar al sistema.
- **Los siniestros con fallecido se mantienen entre 362 y 451 por año de 2016 a 2023**, aunque el total de reportes cayó a menos de la mitad.

PARA EL NEGOCIO

La caída de reportes refleja cambios en la forma de reportar y atender, no una mejora equivalente de la seguridad vial. El indicador confiable a lo largo del tiempo es el de fallecidos.

PARA EL PROYECTO

Un modelo entrenado solo con 2016–2019 no representaría la realidad actual. El año y el periodo del registro entran como variables, y los faltantes se tratan según el periodo en que existía cada campo.

2.6 Hallazgos de apoyo

Hallazgo 4 · El domingo tiene menos reportes pero los más graves

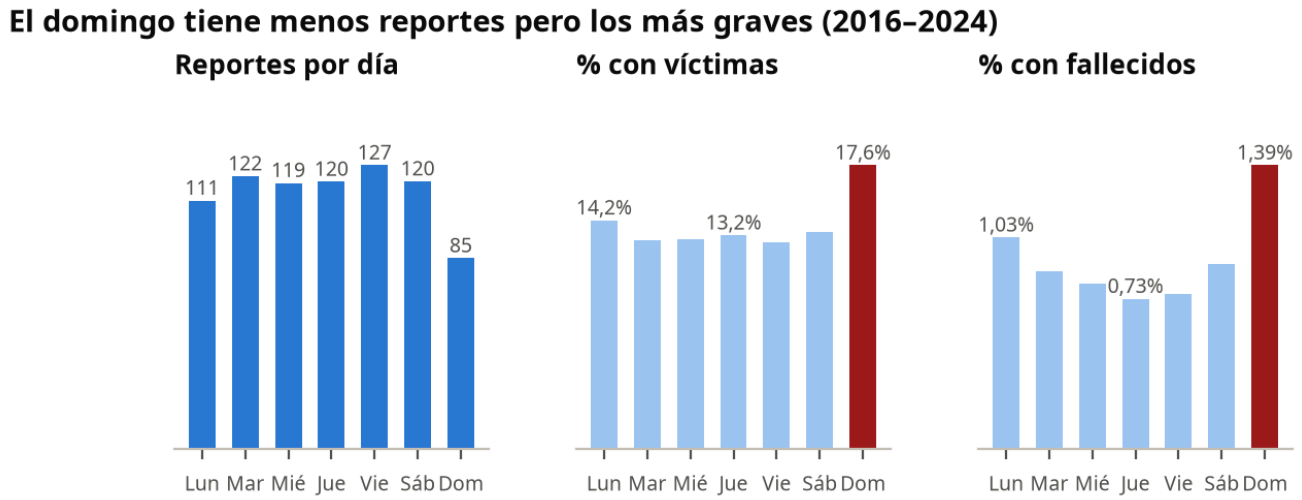


Figura 10. Reportes por día de la semana y porcentaje con víctimas y con fallecidos (2016–2024). El domingo es el día con menos reportes y la mayor proporción de víctimas (17,6 %) y fallecidos (1,4 %, casi el doble que un jueves con 0,7 %). El lunes, día de la mayoría de los festivos en Colombia, es el segundo más letal (1,0 %).

El patrón apunta a más velocidad en vías despejadas y consumo de alcohol en días de descanso. Es una hipótesis que este análisis no evalúa, pero sugiere concentrar los controles en domingos y festivos y no solo en los días de mayor volumen.

Hallazgo 5 · El volcamiento y el atropello son las clases de accidente más letales

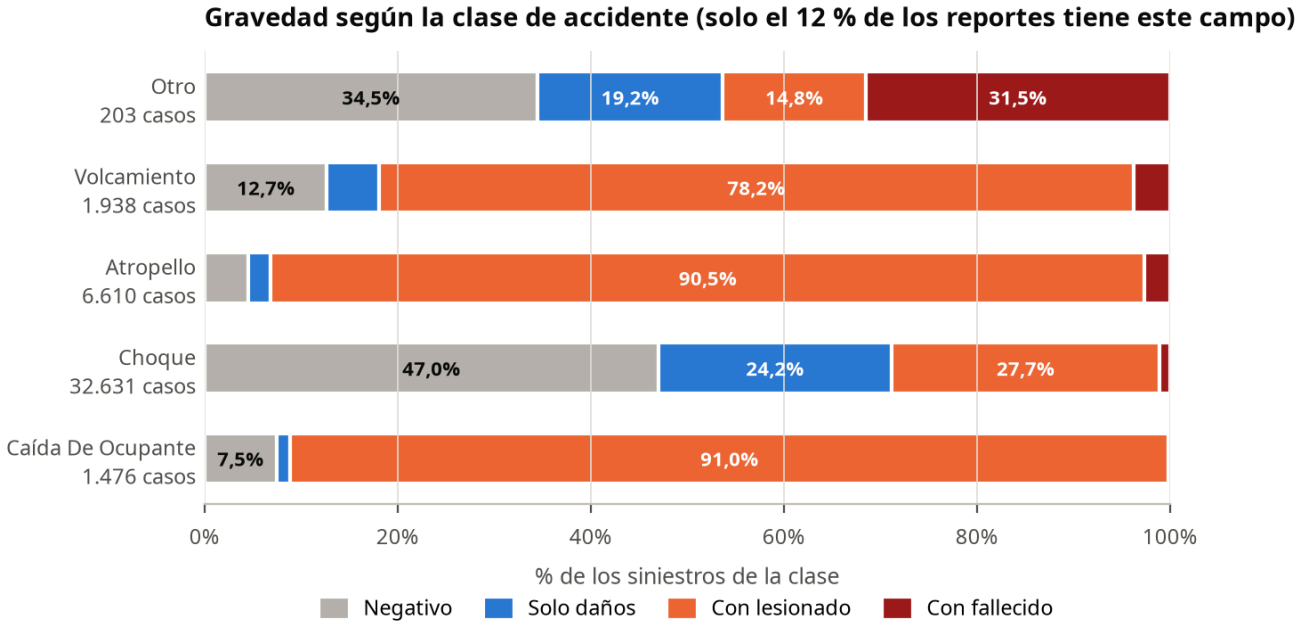


Figura 11. Gravedad según la clase de accidente, solo en los 42.858 reportes que tienen este campo y no son “No aplica”.

Clase de accidente	Reportes	Negativo	Solo daños	Con lesionado	Con fallecido
Caída de ocupante	1.476	7,5 %	1,4 %	**91,0 %**	0,1 %
Choque	32.631	47,0 %	24,2 %	27,7 %	1,1 %
Atropello	6.610	4,5 %	2,4 %	**90,5 %**	2,6 %

Clase de accidente	Reportes	Negativo	Solo daños	Con lesionado	Con fallecido
Volcamiento	1.938	12,7 %	5,4 %	78,2 %	**3,8 %**
Otro	203	34,5 %	19,2 %	14,8 %	31,5 %

Tabla 7. Gravedad según la clase de accidente (Fase A, Sección 8.6).

Atropellos y caídas de ocupante casi siempre dejan víctimas (≈91 % con lesionados). El volcamiento es la clase más letal entre las frecuentes (3,8 %), seguido del atropello (2,6 %); el choque, aunque es la más común, termina en su mayoría sin víctimas. La categoría "Otro" (31,5 % fatal) es muy pequeña y parece usarse para casos registrados a partir del fallecimiento. Como esta variable solo existe en el 12 % de los registros, su uso en el modelado es limitado.

Hallazgo 6 · Los puntos críticos son ejes viales completos, y dos "direcciones" son clínicas

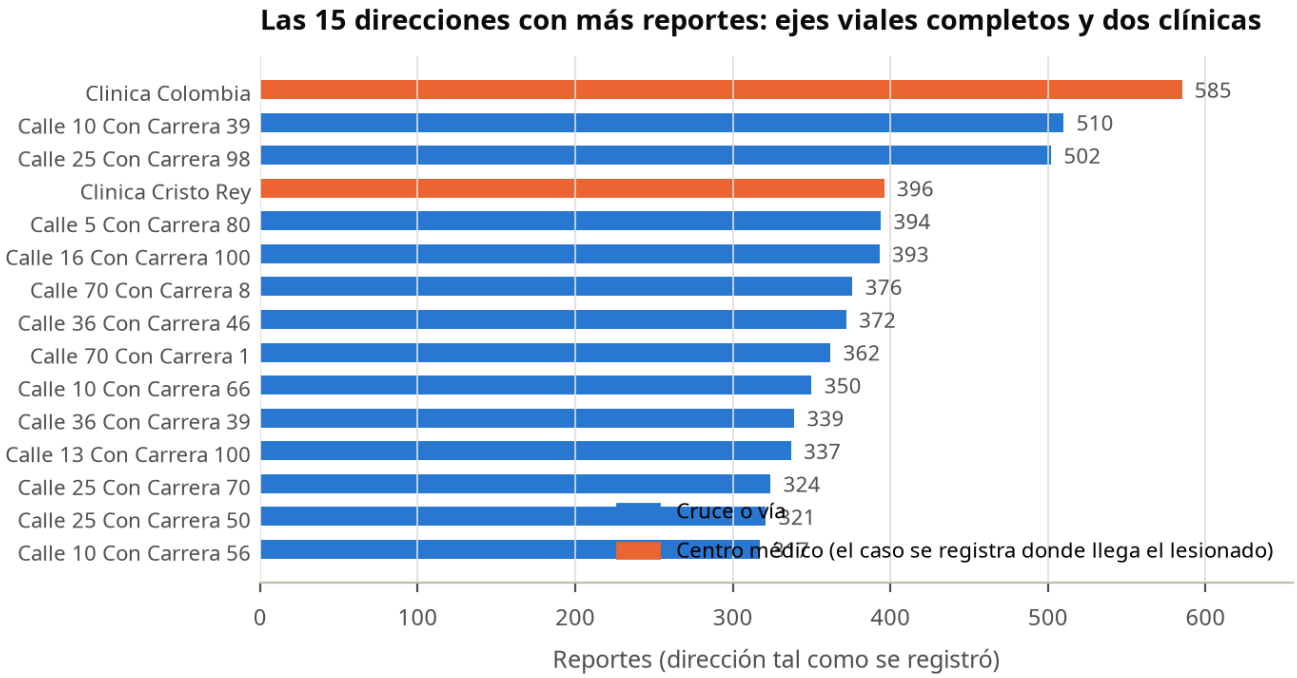


Figura 12. Las 15 direcciones con más reportes. La Calle 10 y la Calle 25 aparecen tres veces cada una, y la Calle 70 y la Calle 36 dos veces: apuntan a corredores completos más que a cruces aislados. Dos de las direcciones son clínicas, donde el caso se registra cuando llega el lesionado y no donde ocurrió.

Antes de cualquier análisis geográfico habría que separar los registros hechos en centros médicos. En la Fase B esas direcciones se agrupan en la categoría `CENTRO MEDICO` del tipo de vía, y esa variable se excluye de los clasificadores por depender del resultado del caso.

2.7 Resumen de la Fase A

#	Hallazgo	Implicación para el negocio	Implicación para las Fases B y C
1	**Motos y bicicletas concentran la gravedad**: con bicicleta el 60 % deja lesionados y el 3,2 % fallecidos; con moto 43 % y 1,7 %; solo autos 11,5 % y 0,3 %.	Priorizar prevención y control para motociclistas y ciclistas.	El tipo de vehículo explica la gravedad entre siniestros confirmados; no sirve para predecir "Negativo" (el dato falta en el 81 % de los Negativo).
2	**66 % de los reportes son "Negativo"** y solo el 0,9 % tiene fallecidos.	Gran costo operativo en atenciones sin siniestro confirmado.	Clases muy desbalanceadas: split estratificado y métricas por clase, no solo accuracy.

#	Hallazgo	Implicación para el negocio	Implicación para las Fases B y C
3	**El registro cambió con el tiempo**: quiebre en 2020, campos que solo existen en ciertos años y casi desaparición de "solo daños" desde 2023, mientras los fallecidos siguen en ≈1 por día.	Menos reportes no significa una ciudad más segura; el indicador confiable son los fallecidos.	Los faltantes dependen del año: no imputar con un solo valor para todo el periodo; incluir el año y el periodo como variables.
4	**Domingo** (y lunes festivo): menos reportes pero la mayor proporción de víctimas y fallecidos.	Controles de velocidad y alcoholemia en domingos y festivos.	El día de la semana entra como categórica (One-Hot), no como número.
5	**Volcamiento y atropello** son las clases más letales; atropellos y caídas de ocupante casi siempre dejan lesionados.	Infraestructura para peatones y control de velocidad.	La clase de accidente solo existe en el 12 % de los registros y antes de 2024 depende del resultado: uso limitado.
6	La regla IQR marca como atípicos siniestros reales (IQR = 0); los días casi vacíos de 2021 son el Paro Nacional; dos "direcciones" frecuentes son clínicas.	Depurar las direcciones antes de un análisis geográfico.	Tratar los outliers con criterio, no eliminarlos por regla automática; agrupar las clínicas como `CENTRO MEDICO`.

Tabla 8. Hallazgos de la Fase A y su implicación en cada frente.

3 Fase B · Limpieza y normalización

El objetivo fue convertir el CSV original en una tabla sin faltantes, con las variables codificadas, transformadas y escaladas, para entrenar los modelos de la Fase C. El pipeline parte de las 371.003 filas originales y termina en **370.996 filas y 34 variables predictoras** sin faltantes, guardadas en `datos_limpios.parquet` junto con la columna `SPLIT`.

> **Regla contra la fuga de datos.** Todo valor que se aprende de los datos (la mediana o la moda para imputar, los parámetros de Yeo-Johnson, la media y la desviación para escalar) se calcula solo con las filas de entrenamiento y después se aplica a train y test. Por eso el split 80/20 estratificado va *antes* de imputar, transformar y escalar, y la partición queda guardada para que la Fase C use exactamente la misma.

3.1 Pipeline en once pasos

1 · Diagnóstico
Nulos, duplicados, texto inconsistente, tipos y extremos

2 · Estructura
`"."` → NaN; fila vacía, duplicados, columna repetida, filas sin objetivo

3 · Texto
Mayúsculas, sin tildes, diccionario por columna; dirección → tipo de vía

4 · Derivadas
Fecha, periodo, conteos por grupo de vehículo, indicador de faltante

5 · Outliers
IQR y Z-score; se corrigen solo 2 valores imposibles

6 · Split
80/20 estratificado por gravedad, guardado en `SPLIT`

7 · Nulos
Mediana, moda o "SIN REGISTRO" según la causa del faltante (train)

8 · Sesgo
Yeo-Johnson en conteos con asimetría > 1 (λ de train)

9 · Encoding
Ordinal para gravedad y periodo; One-Hot para el resto

10 · Escalado
Z-score en conteos, Min-Max en año, mes y periodo (train)

11 · Validación
Sin nulos, un reporte por fila, 4 clases; guardado en parquet

Leyenda
Verde: el paso aprende valores de los datos y se ajusta solo con train

3.2 Diagnóstico

Problema	Columnas	Magnitud	Tratamiento
Faltantes marcados con `"."`	Todas menos código, fecha y gravedad	6 % a 88 % según la columna	Paso 2 (`"."` → NaN) y paso 7 (imputación)
Fila vacía al final del archivo	Todas	1 fila	Paso 2 (eliminar)
Filas duplicadas exactas	Todas	4 filas (mismo código)	Paso 2 (eliminar)
Columna repetida	`Tipo clase de accidente.1`	Idéntica a la original	Paso 2 (eliminar)
Texto inconsistente y tildes dañadas	Gravedad, clase, medio, vehículos, dirección	6 variantes de gravedad, 14 de clase, 17 de medio, 54 tipos de vehículo	Paso 3
Texto libre desplazado	`Medio de reporte`	5 filas con fragmentos de la narración del agente	Paso 3 (dato inválido)
Número guardado como texto	`Numero vehículos` (incluye `"1."`)	Toda la columna	Paso 4
Número sin dato pero con lista de vehículos	`Numero vehículos`	114 filas	Paso 4 (se deriva de la lista)
Valores extremos	`Numero vehículos`	2 casos: 12 y 16 vehículos	Paso 5

Tabla 9. Problemas de calidad detectados en el diagnóstico y el paso del pipeline que los trata.

3.3 Limpieza estructural y normalización de texto

De las 371.003 filas se retiraron 1 fila vacía, 4 duplicados exactos (cada uno es un reporte cargado dos veces; dejarlo contaría doble ese siniestro) y 2 filas sin gravedad: **la variable objetivo nunca se imputa**, porque rellenarla sería inventar la respuesta que el modelo debe aprender. También se eliminó la copia exacta de la clase de accidente. Quedaron 370.996 filas con un código único por fila.

El texto se normalizó en dos pasos: una normalización general (mayúsculas, sin tildes, sin espacios repetidos) y un **diccionario por columna** que unifica variantes y agrupa categorías, de modo que cada equivalencia queda escrita en el código y se puede revisar una por una. La gravedad pasó de 6 variantes a 4 clases; la clase de accidente, de 14 a 6; el medio de reporte, de 17 a 4 (Línea 127, CAD 123, radio y otro); y los 54 tipos de vehículo se agruparon en 6 grupos según el actor vial (motos, autos, transporte público, carga, bicicletas y otros), porque autos y motos suman el 84 % de los vehículos y una columna por tipo dejaría decenas de columnas casi vacías.

Dirección → tipo de vía. La dirección es texto libre con 65.335 valores distintos: como categoría no sirve (One-Hot crearía 65 mil columnas). De la primera palabra se extrae el tipo de vía (calle, carrera, avenida, diagonal/transversal, vía/carretera, otro lugar) unificando abreviaturas (`CRA`, `CR`, `CLL`, `AV`…), y las direcciones que nombran una clínica u hospital quedan como `CENTRO MEDICO` (2.967 reportes), por lo encontrado en la Fase A.

3.4 Conversión de tipos y variables derivadas

Variable nueva	Origen	Tipo	Detalle
`FECHA`, `ANIO`, `MES`, `DIA_SEMANA`	`Fecha`	Fecha / numérica / nominal	El día de la semana es nominal: en la Fase A domingo y lunes fueron los más letales, sin orden lineal
`PERIODO_REGISTRO`	Año del reporte	Ordinal	2016–2019 (245.371) < 2020–2022 (94.753) < 2023–2024 (30.872), según los cambios del registro
`NUM_VEHICULOS`	`Numero vehículos` + largo de la lista	Numérica discreta	`"1."` → 1; si falta el número pero hay lista (114 filas) se usa el largo de la lista (109 recuperados); si no coinciden se toma el mayor
`N_MOTOS` … `N_OTROS`	Lista de vehículos	Numéricas discretas	Conteo por grupo en las 148.783 filas con lista válida; los tokens `"0"` y `"2"` de las filas desplazadas se descartan
`SIN_DATO_VEHICULOS`	¿Falta la lista?	Binaria	Le dice al modelo qué filas tenían el dato y cuáles fueron imputadas
`TIPO_VIA`	`Dirección reporte`	Nominal	Calle 113.288 · Carrera 48.124 · Avenida 12.991 · Diagonal/Transversal 3.964 · Otro lugar 3.511 · Centro médico 2.967 · Vía/Carretera 2.355

Tabla 10. Variables derivadas en el paso 4.

3.5 Valores atípicos

Se aplicaron los dos métodos vistos en clase a los conteos de vehículos, solo en las filas con dato: IQR (fuera de [Q1 − 1,5·IQR, Q3 + 1,5·IQR]) y Z-score ($|z| > 3$).

Variable	Q1	Q3	IQR	Atípicos IQR	Atípicos $\|z\| > 3$	Umbral z (valor)	Máximo
`NUM_VEHICULOS`	2	2	0	28.244	1.290	3,27	16

Variable	Q1	Q3	IQR	Atípicos IQR	Atípicos |z| > 3	Umbral z (valor)	Máximo
N_MOTOS	0	1	1	238	238	2,37	5
N_AUTOS	1	2	1	424	424	3,52	5
N_PUBLICO	0	0	0	13.411	672	1,02	5
N_CARGA	0	0	0	10.486	10.486	0,88	3
N_BICIS	0	0	0	1.307	1.307	0,29	2
N_OTROS	0	0	0	998	998	0,26	2

Tabla 11. Detección de atípicos con IQR y Z-score en los conteos de vehículos (Fase B, paso 5).

La regla IQR falla en estas variables: como casi todos los siniestros tienen exactamente 2 vehículos, marca como atípico cualquier siniestro con 1 o 3 vehículos (≈16 % de los datos), y en transporte público, carga y bicicletas marca *todos* los casos en que ese vehículo aparece. El Z-score marca los siniestros con 4 o más vehículos, que son choques múltiples reales.

> **Decisión.** Se conservan todas las filas y solo se corrigen dos valores imposibles. Los siniestros con 4 a 9 vehículos se quedan: son choques en cadena (varios tienen la lista completa y dejaron lesionados) y su peso en los modelos se reduce en el paso 8 con Yeo-Johnson. Los reportes con 12 y 16 vehículos se tratan como error de captura: son "Negativo" (no se confirmó ningún siniestro), no tienen lista de vehículos y superan de lejos el máximo con lista (9). El número pasa a NaN y se imputa en el paso 7; la fila se conserva porque el resto del reporte es válido. El nuevo máximo es 9.

3.6 Split train/test antes de imputar y escalar

Split 80/20 estratificado por gravedad con semilla 42: **296.796 reportes de entrenamiento y 74.200 de prueba**, con la misma proporción de cada clase en ambos (66,34 % Negativo, 19,95 % Solo daños, 12,80 % Con lesionado y 0,91 % Con fallecido). Sin estratificar, la clase "Con fallecido" podría quedar con muy pocos casos en prueba. La partición se guarda en la columna `SPLIT`.

3.7 Manejo de valores nulos

La Fase A mostró que los faltantes dependen del año y, en algunas columnas, del resultado del caso. Por eso cada columna tiene su estrategia, y se usaron tres distintas (mediana, moda y categoría constante). Todas las medianas y modas se calculan con `SPLIT == "train"`.

Columna	% faltante antes	Estrategia	Justificación	Después
NUM_VEHICULOS	52,4 %	Mediana de train (2)	Distribución asimétrica (asimetría ≈ 1, curtosis ≈ 12). Los choques múltiples suben la media a 1,95, un valor que no existe como conteo; la mediana no se mueve con ellos y es un entero.	0 %
N_MOTOS … N_OTROS	59,9 %	Mediana de train (autos 1; el resto 0) + indicador SIN_DATO_VEHICULOS	Mismo motivo. El indicador conserva la información de qué filas fueron imputadas.	0 %

Columna	% faltante antes	Estrategia	Justificación	Después
`MEDIO_REPORTE`	77,7 %	“SIN REGISTRO” antes de mayo de 2021 · moda de train (Línea 127) desde entonces	El campo apareció en el formulario en mayo de 2021. Rellenar los años anteriores con la moda inventaría unos 290 mil valores; desde 2021 los faltantes son pocos y sueltos.	0 %
`CLASE_ACCIDENTE`	87,7 %	Moda de train (Choque) en 2024 · “SIN REGISTRO” en el resto	En 2024 el campo está casi completo (0,2 % faltante). Antes, la falta depende del resultado (81 % de los Negativo no tiene clase); imputar “Choque” borraría esa diferencia.	0 %
`TIPO_VIA`	49,5 %	“SIN REGISTRO”	La dirección no se capturó entre 2018 y 2020: falta por años completos.	0 %

Tabla 12. Estrategia de imputación por columna (Fase B, paso 7).

Por qué no KNN. KNNImputer completa un valor con el de los vecinos más parecidos, pero aquí las columnas de vehículos faltan juntas (sin lista tampoco hay conteos), los vecinos solo se distinguirían por la fecha, que no tuvo relación con los vehículos (Spearman ≈ 0), y calcular distancias sobre 300 mil filas es costoso sin motivo para esperar algo mejor que la mediana. Las tres categóricas con más del 50 % de faltantes conservan “SIN REGISTRO” como categoría propia: para la Secretaría, esa categoría marca en qué periodos se puede comparar cada indicador.

3.8 Transformación de variables sesgadas

Se comparó la asimetría de cada conteo antes y después de dos transformaciones: `log(1 + x)`, que admite ceros y no aprende parámetros, y Yeo-Johnson (`PowerTransformer`), que busca para cada variable el exponente λ que más la acerca a una normal y se ajusta solo con train.

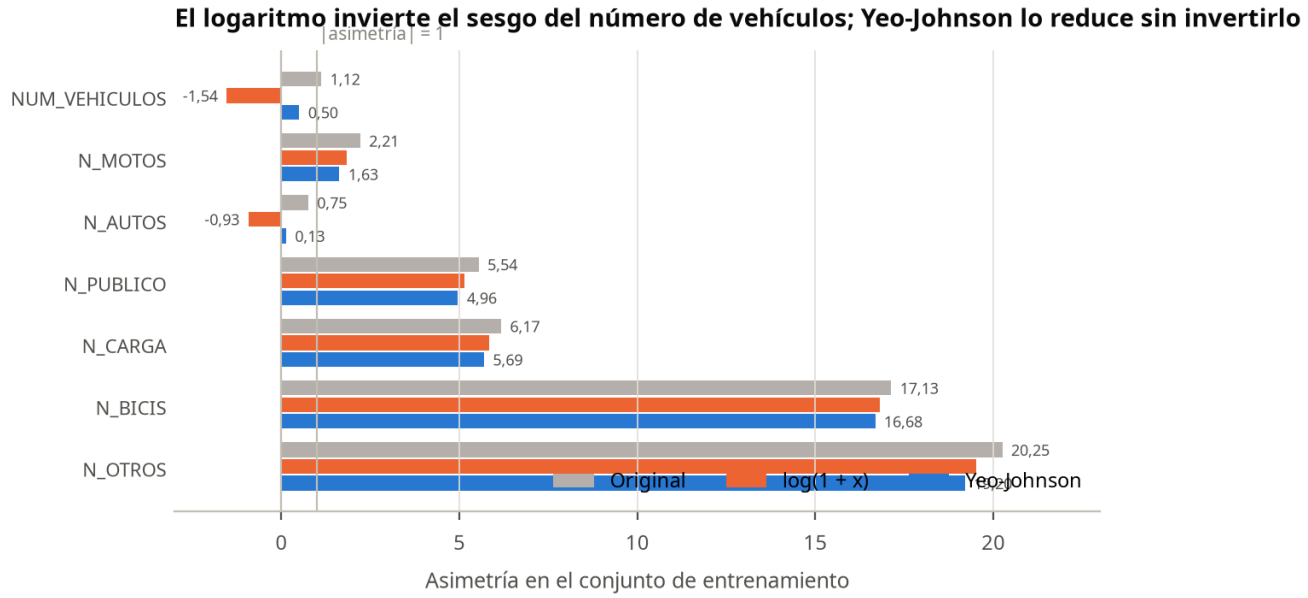


Figura 13. Asimetría de los conteos en entrenamiento: original, con `log(1 + x)` y con Yeo-Johnson. La línea vertical marca |asimetría| = 1, el umbral para transformar.

Decisión. El logaritmo empeora `NUM_VEHICULOS`: después de imputar, la mayoría de los valores es 2, y el log comprime la cola derecha hasta invertir el sesgo (de +1,12 a −1,54), con lo que el extremo pasa a ser el siniestro de un solo vehículo. Yeo-Johnson deja la menor asimetría en todos los conteos (0,50 en `NUM_VEHICULOS`), así que se aplica a las seis columnas con asimetría > 1 en train (λ: 0,82 para el número de vehículos; −7,0 para motos; −38,7 para transporte público; −50,0 para carga; −90,5 para bicicletas y otros). `N_AUTOS` (asimetría 0,75) no se transforma. En bicicletas, carga y transporte público ninguna transformación logra simetría: valen 0 en casi todas las filas y registran un evento raro (el vehículo estuvo o no en el siniestro); los modelos las usan así.

3.9 Encoding de variables categóricas

Variable	Tipo	Encoding	Por qué
`GRAVEDAD` (objetivo)	Ordinal	Ordinal 0–3	Negativo < Solo daños < Con lesionado < Con fallecido: el número sigue el orden de gravedad.
`PERIODO_REGISTRO`	Ordinal	Ordinal 0–2	Los periodos siguen el orden del tiempo.
`CLASE_ACCIDENTE`	Nominal	One-Hot (6 columnas)	Choque, atropello y volcamiento no tienen orden; con números el modelo leería distancias que no existen.
`MEDIO_REPORTE`	Nominal	One-Hot (4 columnas)	El canal de reporte no tiene orden.
`TIPO_VIA`	Nominal	One-Hot (7 columnas)	El tipo de vía no tiene orden.
`DIA_SEMANA`	Nominal	One-Hot (6 columnas; lunes de referencia)	Con el día como número 0–6 un modelo lineal supondría que el riesgo sube o baja de lunes a domingo; la Fase A mostró que no es así.

Tabla 13. Codificación de las variables categóricas (Fase B, paso 9). One-Hot con `drop_first=True`: con k categorías bastan k − 1 columnas; la eliminada queda como referencia y los modelos lineales no reciben columnas perfectamente colineales. Las categorías se fijan en el código para que train y test tengan las mismas 23 columnas.

3.10 Estandarización y normalización

Variables	Escalador	Por qué
`YJ_*` (conteos transformados) y `N_AUTOS`	Z-score (`StandardScaler`)	Tras Yeo-Johnson quedan más cerca de una campana; Z-score las lleva a media 0 y desviación 1, la escala que esperan la regresión logística, KNN, SVM y K-Means.
`ANIO`, `MES`, `PERIODO_NUM`	Min-Max → [0, 1]	Rango fijo y conocido (2016–2024, 1–12, 0–2) y sin outliers; conserva las distancias relativas sin depender de la forma de la distribución.
Dummies One-Hot y `SIN_DATO_VEHICULOS`	Sin escalar	Ya están en {0, 1}.

Tabla 14. Escalado por grupo de variables (Fase B, paso 10). Los escaladores se ajustan solo con train.

RobustScaler no se usó: está pensado para variables con outliers y divide por el IQR, que aquí es 0 en casi todos los conteos; Yeo-Johnson ya redujo el peso de los extremos. Antes de escalar, el año (≈2020) es unas mil veces más grande que un conteo de bicicletas (0 o 1), y un modelo de distancias como K-Means decidiría casi solo por el año. En train las variables Z-score quedan con media 0 y desviación 1 y las Min-Max entre 0 y 1; en test los valores se acercan pero no son idénticos (media de `N_AUTOS` 0,008; desviación 1,002), porque los escaladores no vieron esas filas. Con datos nuevos pasará lo mismo.

3.11 Resultado

El dataset limpio tiene **370.996 filas × 39 columnas**: 34 variables predictoras (7 conteos, 3 de tiempo, 1 indicador y 23 dummies), 3 de control (`CODIGO`, `FECHA`, `SPLIT`) y 2 de objetivo (`GRAVEDAD`, `GRAVEDAD_NUM`). La validación confirmó cero nulos, un reporte por fila, features numéricas y cuatro clases. No pasan al dataset de modelado: `Código` (identificador), `Fecha` (reemplazada por sus derivadas), `Tipo confirmado` (es el objetivo), `Tipo confirmado.1` (**fuga de datos**: describe el resultado con otras palabras, como "Inspección a cadáver" o "Arreglo formal"), la copia de la clase de accidente y la dirección en texto libre.

Paso	Decisión	Justificación
Duplicados	Se eliminan 4 duplicados exactos y la fila vacía	Cada duplicado es un reporte cargado dos veces.
Objetivo	Se eliminan las 2 filas sin gravedad; la gravedad nunca se imputa	Imputarla sería inventar la respuesta.
Texto	Diccionario por columna	Clase 14 → 6; medio 17 → 4; vehículos 54 tipos → 6 grupos.
Nulos numéricos	Mediana de train + indicador	Conteos sesgados; la mediana no se mueve con los extremos y es un entero.
Nulos categóricos	"SIN REGISTRO" donde el campo no existía; moda de train donde los faltantes son sueltos	Los faltantes dependen del periodo y del resultado (Fase A).
Outliers	Se conservan; solo se corrigen 2 valores imposibles	Con IQR = 0 la regla marca casos normales; los choques múltiples son reales.
Sesgo	Yeo-Johnson (λ de train) en conteos con asimetría > 1	log(1 + x) invertía el sesgo (+1,12 → −1,54); Yeo-Johnson lo bajó a 0,50.
Encoding	Ordinal: gravedad y periodo · One-Hot (drop_first): clase, medio, vía, día	Solo las variables con orden reciben números ordenados.
Escalado	Z-score: conteos · Min-Max: año, mes, periodo · ajustados con train	Rangos comparables para los modelos de distancia, sin fuga de datos.

Tabla 15. Resumen de las decisiones de la Fase B.

4 Fase C · Modelos de clasificación

Se entrenaron tres clasificadores para estimar la gravedad registrada de cada reporte, usando la partición de la Fase B y evaluando solo en el conjunto de prueba. Se conservó la columna `SPLIT` en lugar de repetir `train_test_split`: las imputaciones y los escaladores se ajustaron con ese conjunto de entrenamiento y repartir de nuevo mezclaría filas de prueba en el ajuste.

4.1 Variables y configuración

Los modelos usan **20 variables**. Se excluyeron los identificadores, las dos representaciones del objetivo y, por el Hallazgo 4, las variables que pueden reflejar cómo se registró el resultado y no el siniestro: la clase de accidente (antes de 2024 solo se llena al confirmar), el tipo de vía (incluye `CENTRO MEDICO`) y el indicador de vehículos faltantes (vacío ⇒ casi siempre Negativo).

Grupo	Variables	Número
Conteos de vehículos	Número de vehículos, motos, autos, transporte público, carga, bicicletas y otros (seis transformados con Yeo-Johnson y estandarizados; autos solo estandarizado)	7
Tiempo	Año, mes y periodo del registro (Min-Max)	3
Medio de reporte	Línea 127, CAD 123, radio y otro (One-Hot; “sin registro” de referencia)	4
Día de la semana	Martes a domingo (One-Hot; lunes de referencia)	6

Tabla 16. Las 20 variables predictoras de los clasificadores y de K-Means.

Modelo	Por qué se incluye	Configuración
Regresión logística	Modelo lineal sencillo y fácil de explicar; punto de comparación.	`max_iter=1000`, `class_weight="balanced"`, semilla 42
Árbol de decisión	Aprende reglas e interacciones no lineales; se puede leer.	`max_depth=8`, `class_weight="balanced"`, semilla 42
Random Forest	Ensamble de árboles con muestras y subconjuntos de variables aleatorios; compara un ensamble con un clasificador individual.	`n_estimators=200`, `max_depth=8`, `class_weight="balanced"`, semilla 42

Tabla 17. Modelos y configuraciones. Las configuraciones se fijaron antes de evaluar, tomadas de los ejemplos de clase; no se hizo búsqueda de hiperparámetros. `class_weight="balanced"` da más peso a las clases minoritarias durante el entrenamiento.

Criterio de comparación. Como “Negativo” es el 66,34 % de los reportes y “Con fallecido” el 0,91 %, el criterio principal es el **F1 macro**, que combina precision y recall y da el mismo peso a cada clase. También se reportan accuracy, precision y recall macro, F1 ponderado, métricas por clase y matrices de confusión. Como referencia, un modelo que siempre responde “Negativo” logra accuracy 0,6634 y F1 macro 0,1994: un acierto alto se consigue sin identificar ningún reporte de las otras tres clases. El conjunto de prueba tiene 49.222 reportes Negativo, 14.806 Solo daños, 9.500 Con lesionado y 672 Con fallecido.

4.2 Métricas globales

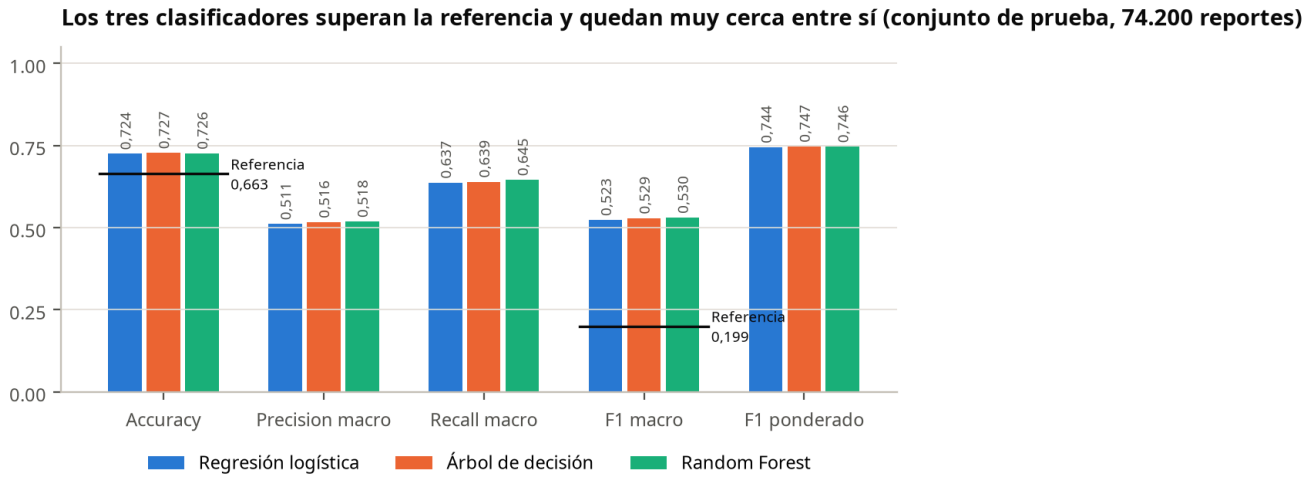


Figura 14. Métricas globales de los tres clasificadores en el conjunto de prueba. Las líneas negras marcan la referencia "siempre Negativo" en accuracy (0,663) y F1 macro (0,199).

Modelo	Accuracy	Precision macro	Recall macro	F1 macro	F1 ponderado	AUC macro*
Referencia: siempre "Negativo"	0,6634	—	—	0,1994	—	0,500
Regresión logística	0,7243	0,5107	0,6369	0,5230	0,7444	0,815
Árbol de decisión	**0,7270**	0,5164	0,6394	0,5287	**0,7469**	0,836
Random Forest	0,7256	**0,5182**	**0,6448**	**0,5303**	0,7458	**0,840**

Tabla 18. Métricas en el conjunto de prueba (74.200 reportes); en negrita el mejor valor de cada columna. *AUC uno contra todos promediado entre las 4 clases, calculado para este informe con las mismas configuraciones (Sección 4.6).

Los tres modelos superan con claridad la referencia, pero quedan muy cerca entre sí: el accuracy está entre 0,7243 y 0,7270 y el F1 macro entre 0,5230 y 0,5303. Random Forest tiene el mayor F1 macro, pero su ventaja sobre el árbol es de solo 0,0016, y el árbol tiene el mayor accuracy. Ningún modelo domina en todos los criterios. La distancia entre el accuracy (≈0,73) y el F1 macro (≈0,53) muestra por qué hay que examinar cada clase en un dataset desbalanceado.

4.3 Desempeño por clase

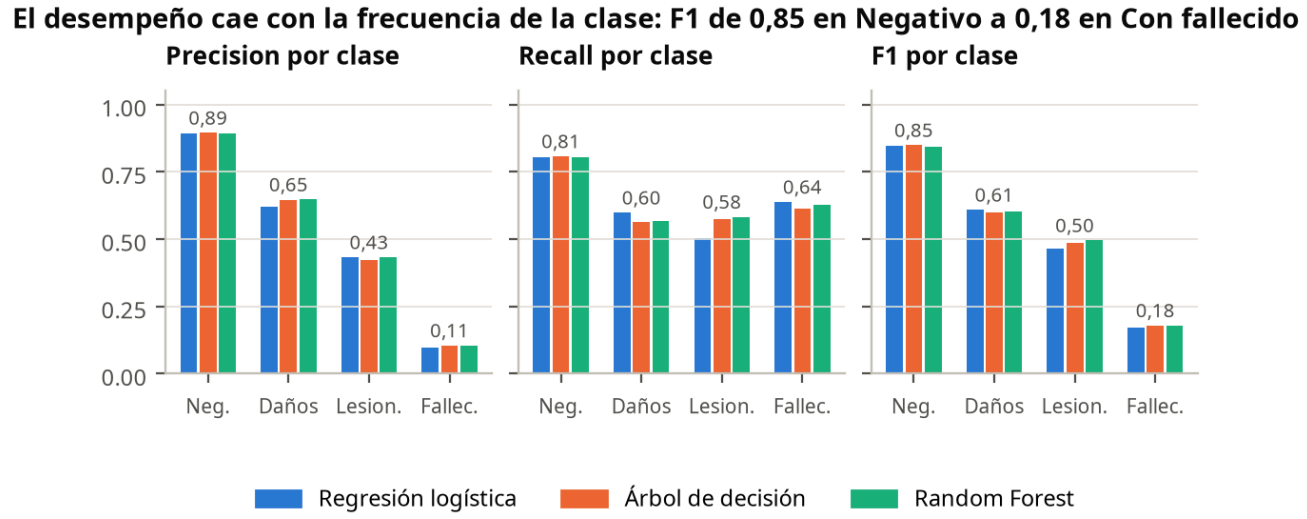


Figura 15. Precision, recall y F1 por clase y modelo en el conjunto de prueba. El número sobre cada grupo es el mejor valor de los tres modelos.

Modelo	Negativo			Solo daños			Con lesionado			Con fallecido		
	P	R	F1	P	R	F1	P	R	F1	P	R	F1
Regresión logística	0,892	0,806	0,847	0,620	0,598	**0,609**	0,433	0,505	0,466	0,098	**0,638**	0,170
Árbol de decisión	0,895	0,808	**0,849**	0,644	0,562	0,600	0,421	0,573	0,486	0,105	0,615	**0,180**
Random Forest	0,891	0,802	0,845	0,647	0,566	0,604	0,431	0,583	**0,496**	0,103	0,628	0,177

Tabla 19. Precision (P), recall (R) y F1 por clase en el conjunto de prueba; en negrita el mejor F1 de cada clase y el mejor recall en fallecidos.

El F1 baja con la frecuencia de la clase: de 0,84–0,85 en “Negativo” a 0,17–0,18 en “Con fallecido”. Ningún modelo es el mejor en todas las clases: la regresión logística gana en “Solo daños” y en el recall de fallecidos, el árbol en “Negativo” y en el F1 de fallecidos, y Random Forest en “Con lesionado”, la clase más difícil entre las frecuentes (su recall sube de 50,5 % con la regresión a 58,3 % con Random Forest).

4.4 Matrices de confusión

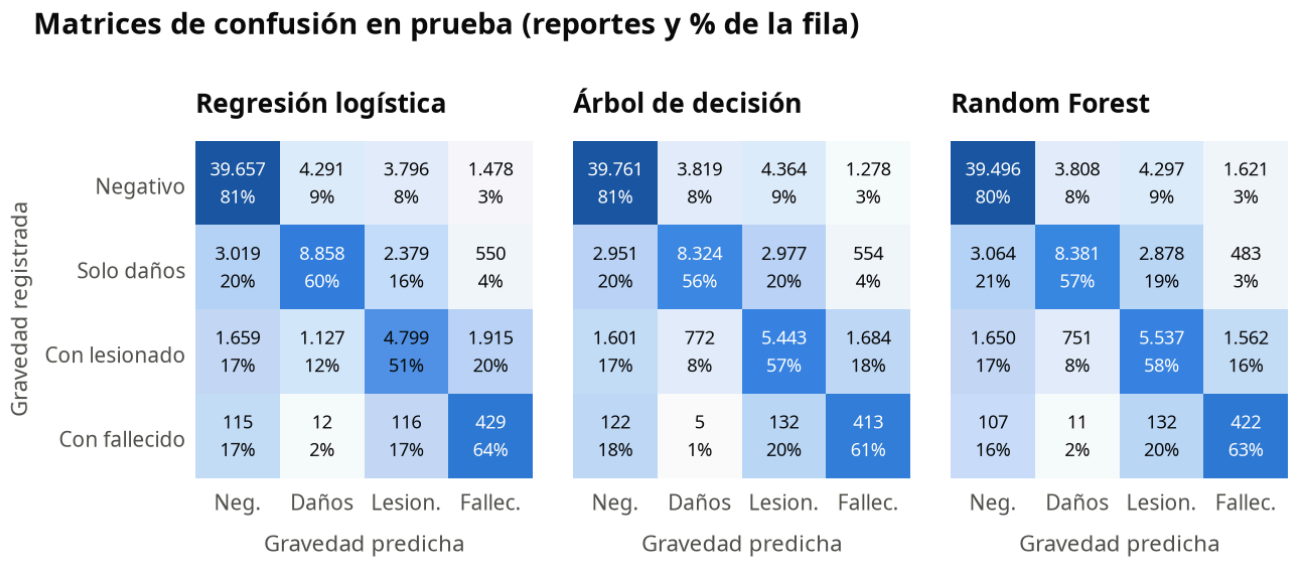


Figura 16. Matrices de confusión en prueba. Filas: gravedad registrada; columnas: gravedad predicha. Cada celda muestra el número de reportes y el porcentaje de su fila; el color sigue ese porcentaje.

“Negativo” se acierta en cerca del 80 % de los casos; sus errores van sobre todo a “Solo daños” y “Con lesionado” (unos 4.000 reportes cada uno). “Solo daños” se acierta en el 56–60 % y se confunde con las dos clases vecinas. “Con lesionado” se confunde principalmente con “Negativo” (≈1.600) y con “Con fallecido” (1.560–1.915), lo que explica la baja precisión de la clase fatal. En “Con fallecido” los errores van sobre todo hacia “Negativo” y “Con lesionado”; casi nunca hacia “Solo daños”.

4.5 La clase “Con fallecido”

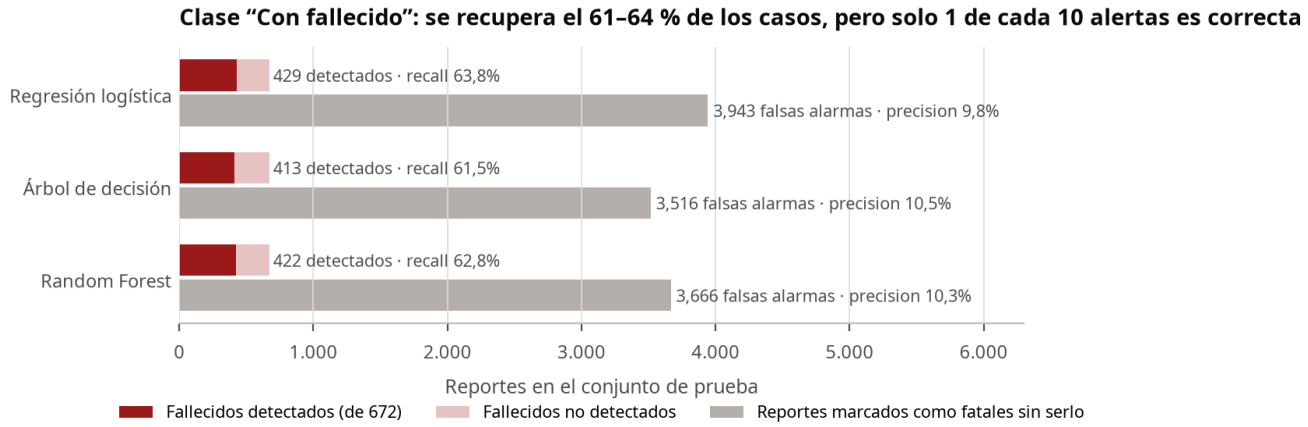


Figura 17. Clase “Con fallecido” en el conjunto de prueba: casos detectados y no detectados (de 672) frente a los reportes marcados como fatales sin serlo.

Modelo	Precision	Recall	F1	Detectados (de 672)	No detectados	Falsas alarmas
Regresión logística	0,0981	**0,6384**	0,1701	**429**	243	3.943
Árbol de decisión	**0,1051**	0,6146	**0,1795**	413	259	**3.516**
Random Forest	0,1032	0,6280	0,1773	422	250	3.666

Tabla 20. Desempeño en la clase “Con fallecido” (conjunto de prueba).

Los modelos recuperan entre el 61 % y el 64 % de los reportes con fallecido, pero **solo una de cada diez alertas de esa clase es correcta**. Con Random Forest, 250 de los 672 casos fatales quedan clasificados en otra categoría y 3.666 reportes se marcan como fatales sin serlo. El árbol reduce las falsas alarmas (3.516) a costa de detectar 16 casos menos que la regresión logística. La elección depende de qué error se considere más costoso; con esta precisión el modelo sirve para ordenar o estudiar registros con supervisión humana, no como criterio único para decidir sobre un reporte individual.

4.6 Curvas ROC

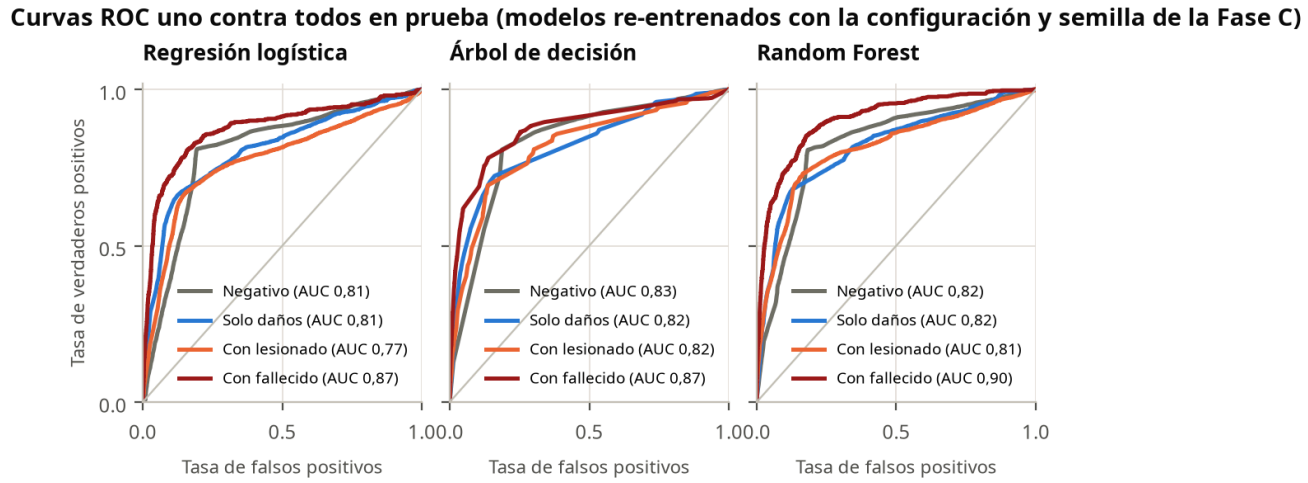


Figura 18. Curvas ROC uno contra todos en prueba, con el AUC de cada clase. Los modelos se re-entrenaron para este informe con la configuración y la semilla de la Fase C; el accuracy y el F1 macro obtenidos coinciden con los del notebook en los tres modelos.

Las curvas confirman que los modelos separan las clases mucho mejor que el azar (la diagonal). La clase “Con fallecido” es la mejor separada (AUC de 0,87 a 0,90 según el modelo), seguida de “Negativo” (0,81–0,83); las clases intermedias, “Solo daños” y “Con lesionado”, quedan entre 0,77 y 0,82. Que el AUC de fallecidos sea alto mientras su precisión es del 10 % se explica por el desbalance: separar bien 672 casos de 73.528 no basta para que las alertas sean mayoritariamente correctas.

5 Fase C · Segmentación con K-Means

K-Means se aplicó sobre las mismas 20 variables, **sin usar la gravedad**, para identificar perfiles de reportes con características similares. Se compararon de 2 a 10 grupos con Silhouette (mayor es mejor) y Davies-Bouldin (menor es mejor) sobre una muestra reproducible de 10.000 reportes de entrenamiento (Silhouette sobre 2.000 de ellos), sin consultar el conjunto de prueba ni las etiquetas.

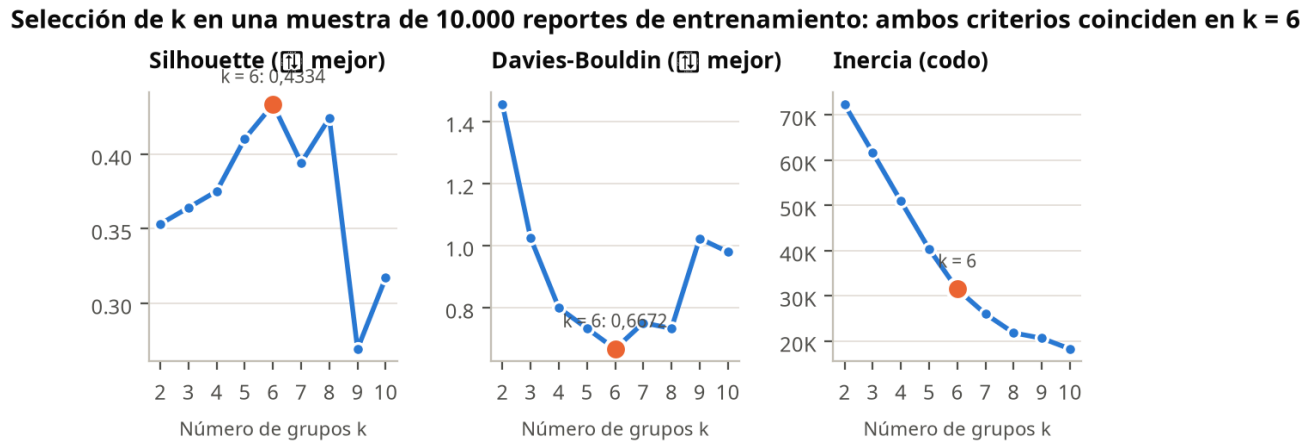


Figura 19. Silhouette, Davies-Bouldin e inercia para k de 2 a 10. Con k = 6 se obtiene el mayor Silhouette (0,4334) y el menor Davies-Bouldin (0,6672); la inercia no muestra un codo nítido.

k	2	3	4	5	6	7	8	9	10
Silhouette	0,353	0,364	0,375	0,411	**0,433**	0,394	0,424	0,269	0,317
Davies-Bouldin	1,454	1,024	0,800	0,733	**0,667**	0,751	0,733	1,023	0,980
Inercia	72.329	61.670	50.922	40.359	31.456	25.976	21.770	20.587	18.228

Tabla 21. Selección del número de grupos en la muestra de entrenamiento. La elección de k = 6 corresponde al rango, la muestra y las variables evaluadas; no demuestra que existan exactamente seis grupos naturales.

El modelo final se ajustó con todo el train y los reportes de test se asignaron a los centros aprendidos. Sobre 2.000 reportes de prueba, Silhouette 0,4261 y Davies-Bouldin 0,6779, cercanos a los de la exploración aunque no equivalentes porque se calculan sobre otra muestra. Estas métricas describen la estructura de los grupos, no la capacidad de predecir gravedad. En esa muestra hay solo 6 reportes del grupo 1 y 3 del grupo 5, así que dicen poco sobre ellos.

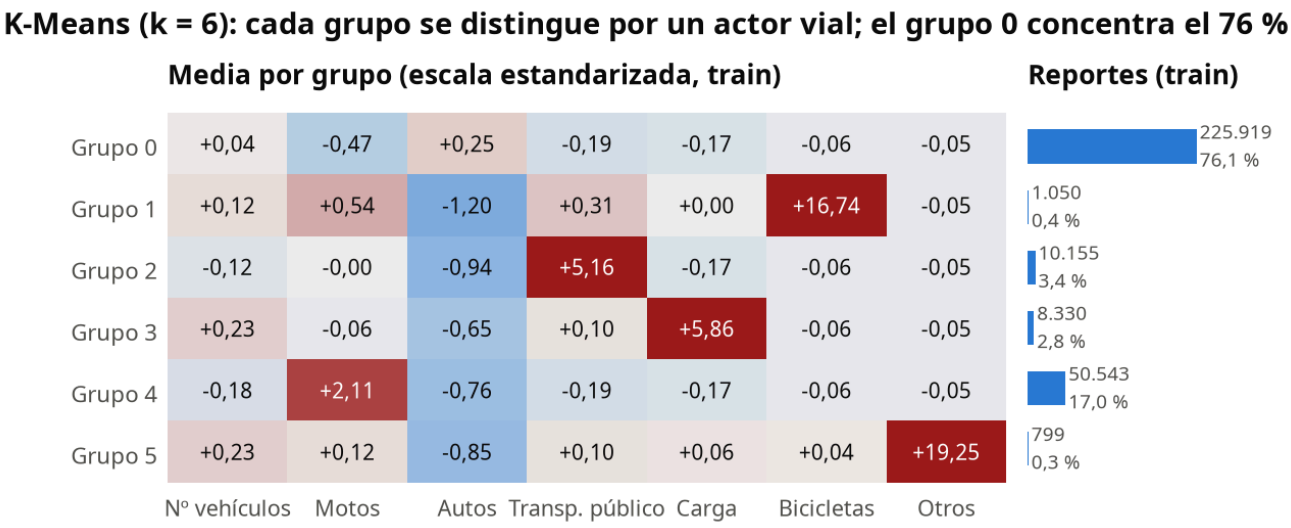


Figura 20. Perfil de cada grupo: media de las variables de vehículos en escala estandarizada (azul por debajo de la media general, rojo por encima) y número de reportes de entrenamiento por grupo.

Grupo	Train	Test	Perfil destacado	Negativo	Solo daños	Con lesionado	Con fallecido
0	225.919	56.486	Mayor valor relativo de autos; posible mezcla con registros imputados	77,1 %	17,1 %	5,1 %	0,7 %
1	1.050	251	Bicicletas	29,9 %	6,4 %	**61,0 %**	**2,8 %**
2	10.155	2.526	Transporte público	22,5 %	45,3 %	31,2 %	1,0 %
3	8.330	2.078	Vehículos de carga	28,3 %	56,9 %	13,4 %	1,4 %
4	50.543	12.660	Motocicletas	34,6 %	21,5 %	**42,3 %**	1,5 %
5	799	199	Otros vehículos	24,9 %	51,2 %	22,7 %	1,3 %

Tabla 22. Tamaño y perfil de cada segmento. Las cuatro últimas columnas (gravedad dentro del grupo, en train) se calcularon para el informe; el notebook no las incluye.

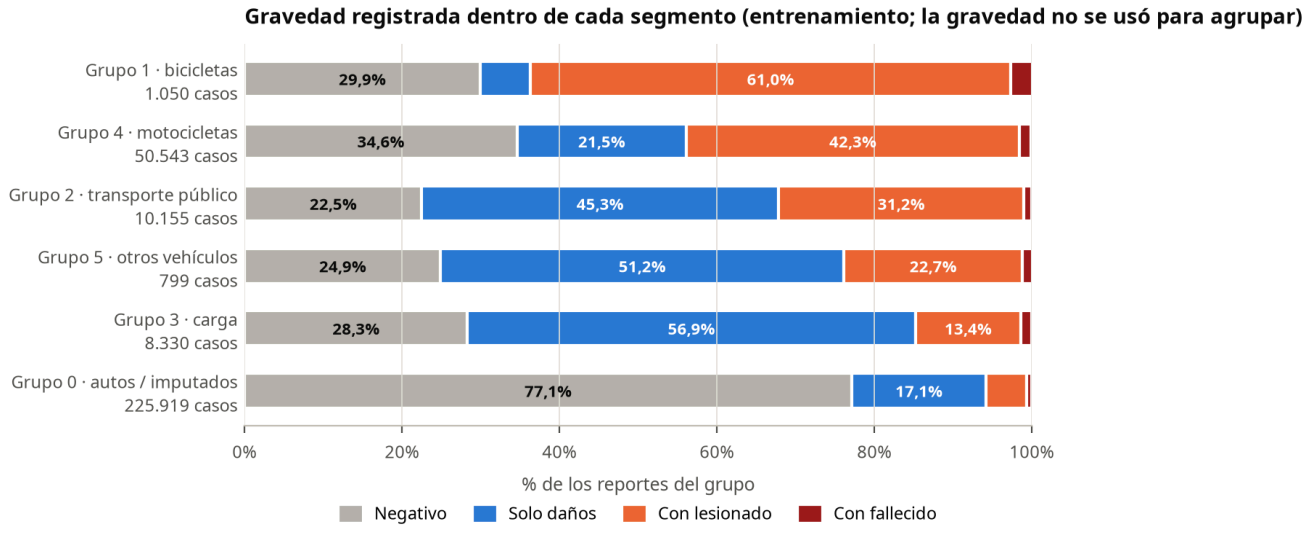


Figura 21. Gravedad registrada dentro de cada segmento. Aunque la gravedad no se usó para agrupar, los segmentos de bicicletas y motos reproducen el Hallazgo 1.

Los seis segmentos se distinguen sobre todo por el actor vial: el grupo 4 destaca en motocicletas, el 2 en transporte público, el 3 en carga, el 1 en bicicletas y el 5 en otros vehículos. El grupo 0 concentra cerca del 76 % de los reportes y tiene una media de autos superior a la general. Al cruzar los segmentos con la gravedad

se ve lo mismo que en el análisis exploratorio: los grupos de bicicletas (61,0 % con lesionados) y motos (42,3 %) tienen mucha más gravedad que el grupo 0 (5,1 %). Es una descripción, no una prueba de que el segmento cause el resultado; los grupos 1 y 5 son pequeños (1.050 y 799 reportes de train) y se leen con cautela; y las medias corresponden a variables transformadas, imputadas y estandarizadas, no a cantidades originales de vehículos: el grupo 0 puede mezclar reportes con autos y reportes con valores imputados.

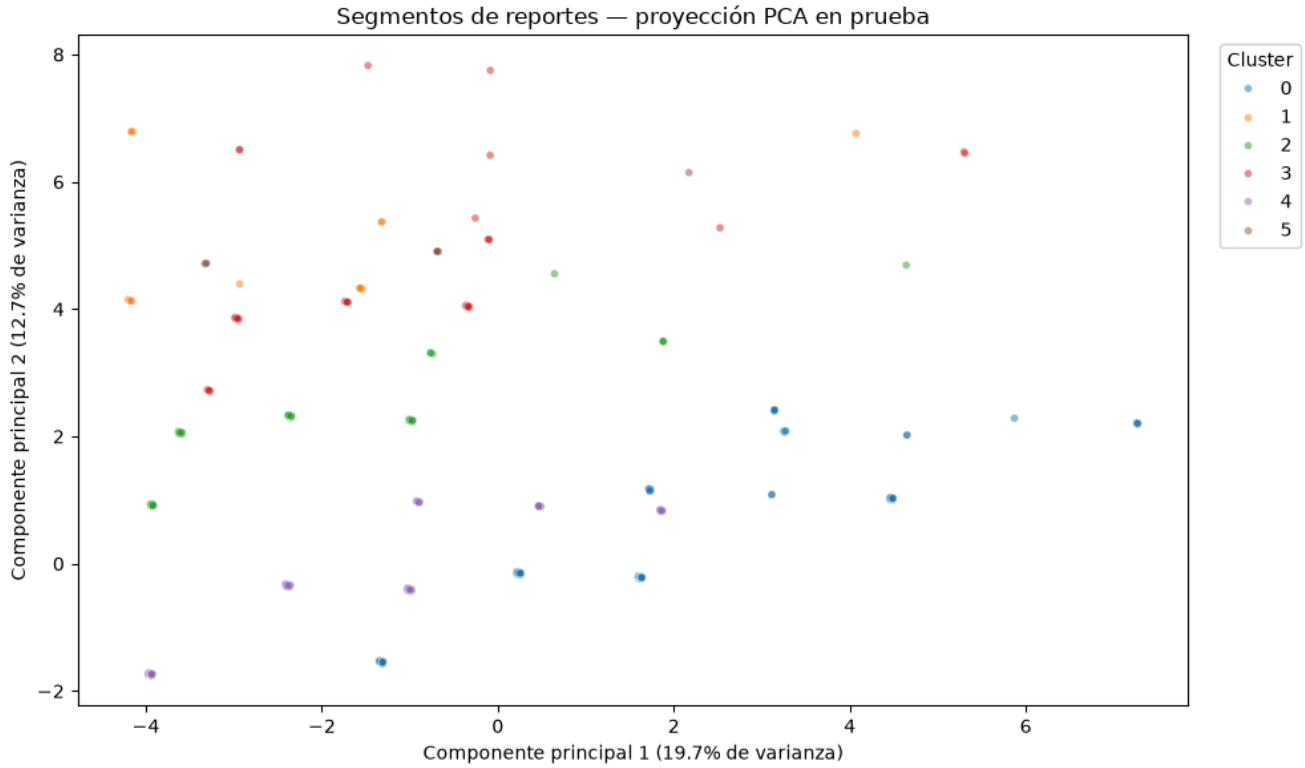


Figura 22. Segmentos K-Means proyectados en dos componentes principales (PCA ajustado solo con train; 5.000 reportes de prueba). Los dos componentes conservan el 32,35 % de la varianza. Gráfico tomado del notebook de la Fase C.

La proyección PCA sirve para visualizar, no para comparar tamaños de grupos: como casi todas las variables son discretas, muchos puntos se superponen, y el 67,65 % de la variabilidad queda fuera del gráfico. Los ejes son combinaciones de variables, no medidas de gravedad ni de riesgo. Los segmentos pueden reflejar también diferencias de captura entre periodos, y sus números son identificadores, no niveles de riesgo.

PARA EL NEGOCIO

La segmentación permite organizar la revisión de reportes por perfiles de actores viales y confirma, por un camino independiente, que motos y bicicletas son el frente prioritario.

PARA EL PROYECTO

K-Means encontró estructura en las variables de vehículos, no en el tiempo ni en el medio de reporte (sus medias apenas varían entre grupos). La estabilidad de los grupos con otras muestras y semillas queda por evaluar.

6 Modelo elegido y justificación

Modelo final: Random Forest, entre las configuraciones evaluadas. Se eligió porque tiene el mayor F1 macro (0,5303), el criterio principal por dar el mismo peso a cada clase en un problema donde “Con fallecido” es solo el 0,91 % de los reportes. También tiene la mayor precision macro (0,5182), el mayor recall macro (0,6448), el mayor F1 en “Con lesionado” (0,4956) y el mayor AUC macro (0,840). La decisión tiene límites claros:

- La ventaja sobre el árbol es de solo 0,0016 de F1 macro y proviene de una sola partición, así que no demuestra superioridad consistente. Si el criterio fuera la simplicidad y la lectura de reglas, **el árbol de**

decisión es una alternativa razonable: tiene el mayor accuracy (0,7270), el mayor F1 en fallecidos (0,1795) y la menor cantidad de falsas alarmas fatales (3.516).

- La **regresión logística** es la más simple de explicar y alcanza el mayor recall en fallecidos (63,8 %), a costa de más falsas alarmas (3.943).
- Random Forest no es el mejor en fallecidos y su precisión en esa clase es del 10,3 %: es un resultado experimental del proyecto, no una herramienta para decidir sobre casos individuales.

El ejercicio clasifica reportes históricos con la información disponible; no demuestra capacidad de anticipar la gravedad antes de que ocurra un siniestro. Además, los datos de vehículos pueden haberse obtenido al confirmar el reporte, por lo que antes de un uso operativo habría que verificar qué información existe realmente al momento de clasificar.

7 Limitaciones y alcance de los resultados

Los siguientes límites no invalidan el trabajo, pero acotan lo que se puede afirmar con él.

Limitación	En qué consiste	Qué habría que hacer
Una sola partición	Los resultados vienen de un split aleatorio y no garantizan el mismo desempeño en años futuros, sobre todo por los cambios de captura. La selección se hizo comparando en el conjunto de prueba, como exige el proyecto.	Elegir configuraciones con validación cruzada dentro de train y reservar una prueba independiente; evaluar por año (entrenar 2016–2022, probar 2023–2024).
Configuraciones iniciales	La profundidad 8 y los 200 árboles se tomaron de los ejemplos de clase. Limitar la profundidad restringe la complejidad, pero no demuestra por sí solo que se evitó el sobreajuste.	Búsqueda de hiperparámetros y comparación de métricas en train y test.
Ponderación de clases	`class_weight="balanced"` aumenta el peso de las clases minoritarias, pero puede aumentar las falsas alarmas; no se evaluó una configuración sin ponderar para medir ese efecto.	Comparar con y sin ponderación y ajustar el umbral de decisión de “Con fallecido”.
Datos que dependen del registro	Aun excluyendo las variables más ligadas al resultado, el medio de reporte (existe desde mayo de 2021), el año y el periodo pueden reflejar cambios del formulario más que características del siniestro.	Verificar qué información existe realmente en el momento de clasificar.
Clasificación, no predicción	El modelo asigna una gravedad a reportes que ya ocurrieron; no anticipa accidentes ni su gravedad, y sus datos de vehículos pueden ser posteriores a la ocurrencia.	Reformular el problema (por ejemplo, grave vs. no grave entre confirmados) si se busca un uso anticipado.
Segmentos descriptivos	Los grupos 1 y 5 son muy pequeños, los números de cluster no son una jerarquía de riesgo y el grupo 0 puede mezclar reportes con autos y reportes imputados.	Evaluar la estabilidad con otras muestras y semillas; probar K-Means solo sobre reportes con dato de vehículos.
Sin comparación con y sin limpieza	No se midió el desempeño de los modelos sobre los datos sin limpiar, así que no se afirma cuánto aportó la Fase B al modelado.	Entrenar una línea base con imputación mínima y comparar.

Tabla 23. Limitaciones del proyecto y mejoras asociadas.

8 Recomendaciones para la Secretaría de Movilidad

Las recomendaciones se derivan de lo observado en los datos. Donde el análisis apunta a una explicación, se indica que es una hipótesis y no algo que el proyecto haya probado.

1. **Priorizar la prevención en motociclistas y ciclistas.** Con bicicleta el 60,3 % de los siniestros deja lesionados y con moto el 42,7 %, frente al 11,5 % cuando solo hay autos; los segmentos de bicicletas y motos de K-Means muestran lo mismo. Campañas, carriles y cruces seguros y controles dirigidos a estos actores son las medidas con mayor impacto en vidas.
2. **Seguir los fallecidos y los lesionados como indicadores propios.** Los fallecidos son el 0,9 % de los reportes, pero se mantienen en 362–451 por año mientras el total de reportes cae a menos de la mitad; los promedios y el volumen de reportes esconden ese problema.
3. **Mantener un formulario estable y completo.** Hoy no se puede saber, para todo el periodo, cuántos atropellos hubo ni si una intervención funcionó, porque el dato no existía antes. Volver obligatorios el tipo de vehículo y la clase de accidente, y registrarlos en todos los reportes y no solo en los confirmados, es la mejora con más efecto.
4. **Revisar los controles de fin de semana.** El domingo concentra los siniestros más graves (17,6 % con víctimas y 1,4 % con fallecidos) y el lunes festivo le sigue. Las razones (velocidad en vías despejadas, consumo de alcohol) son hipótesis que este análisis no evalúa.
5. **Mirar ejes viales completos y depurar las direcciones.** Las calles 10 y 25 aparecen tres veces cada una entre las 15 direcciones más frecuentes; antes de un análisis geográfico hay que separar los registros hechos en clínicas y normalizar las direcciones.
6. **Reducir el costo de los reportes "Negativo".** Dos de cada tres salidas del agente no terminan en un siniestro confirmado (20.663 "No quiere intervención" y 3.773 "Falsa alarma" solo en el detalle registrado). Un filtro previo en la recepción del reporte liberaría capacidad de atención.
7. **Usar los modelos solo como apoyo a la revisión.** Con una precisión del 10 % en fallecidos, sirven para ordenar o estudiar reportes con supervisión humana, no para decidir sobre casos individuales.

9 Conclusiones y posibles mejoras

Conclusiones

- **Análisis.** La gravedad se asocia sobre todo con el actor vial. Bicicleta y moto concentran lesionados y fallecidos, y la segmentación lo confirma de forma independiente. Los fallecidos (0,9 %) son la clase más escasa y la más costosa, por lo que no se deben priorizar los problemas solo por volumen de casos. El volumen de reportes depende de cómo se registra, no solo de cuántos siniestros ocurren.
- **Limpieza.** Casi todas las decisiones dependieron de entender *por qué* faltaba cada dato. Los faltantes siguen los cambios del formulario y el resultado del caso; por eso varias columnas conservan "SIN REGISTRO", los outliers se conservaron con criterio y las variables más ligadas al registro del resultado se excluyeron del modelado. El pipeline deja 370.996 filas y 34 variables sin faltantes, con todo lo aprendido ajustado solo con train.
- **Modelado.** Los tres clasificadores superan la referencia (F1 macro 0,523–0,530 frente a 0,199), con diferencias mínimas entre ellos y baja precisión en fallecidos (≈10 %). Random Forest es el elegido por F1 macro; el árbol es una alternativa razonable si se prioriza la interpretabilidad. Son útiles para estudiar los registros, con las salvedades de las secciones 6 y 7.
- **Segmentación.** K-Means con k = 6 organiza los reportes por perfiles de vehículos (Silhouette 0,43; Davies-Bouldin 0,67); el grupo 0 concentra el 76 % y los grupos de bicicletas y motos reproducen el patrón de gravedad del análisis exploratorio sin haber visto la gravedad.

Posibles mejoras

Frente	Mejora
Evaluación más sólida	Seleccionar modelos con validación cruzada dentro de train y reservar el test para la evaluación final; medir el desempeño por año (entrenar con 2016–2022 y probar con 2023–2024) para ver el efecto de los cambios del registro; evaluar la estabilidad de los segmentos con otras muestras y semillas.
Hiperparámetros y ponderación	Buscar profundidad y número de árboles; comparar con y sin `class_weight`; probar Gradient Boosting; ajustar el umbral de decisión de la clase fallecido para equilibrar detección y falsas alarmas.
Reformular el objetivo	Predecir gravedad solo entre siniestros confirmados (grave vs. no grave), donde las variables de vehículos no sufren el sesgo de registro, y modelar aparte la probabilidad de que un reporte sea "Negativo" con las variables disponibles al recibirlo.
Más variables	Hora del día, ubicación (barrio o coordenadas), estado de la vía, clima y velocidad. El modelo hoy no ve dónde ni a qué hora ocurrió el siniestro. La fuente de lesionados 2016–2025 de la misma entidad trae hora y condición de peatón o ciclista.
Calidad del registro	Mantener el mismo formulario durante años y volver obligatorios el tipo de vehículo y la clase de accidente. Es la mejora con más efecto, porque limita lo que cualquier modelo puede aprender de estos datos.
Más datos	Los casos con fallecido son 3.360; sumar fuentes (por ejemplo, Medicina Legal) estabilizaría las métricas de esa clase.

Tabla 24. Mejoras propuestas por frente.

A Glosario de métricas

Término	Qué significa
Accuracy	Proporción de reportes clasificados en su clase correcta. Engaña si una clase domina: aquí "Negativo" es el 66 %, así que responder siempre "Negativo" da 0,66.
Precision y recall (de una clase)	Precision: de los reportes que el modelo asigna a la clase, cuántos pertenecen realmente a ella. Recall: de los que realmente son de la clase, cuántos detecta.
F1	Media armónica de precision y recall; resume ambos en un número y castiga el desequilibrio entre ellos.
Macro y ponderado	Macro: promedio simple entre las 4 clases, de modo que la clase escasa pesa igual. Ponderado: cada clase pesa según su número de casos.
Matriz de confusión	Tabla que cruza la clase registrada (filas) con la predicha (columnas); la diagonal son los aciertos.
AUC (uno contra todos)	Área bajo la curva ROC: capacidad de separar una clase del resto al variar el umbral. 0,5 equivale al azar y 1 es una separación perfecta.
Silhouette y Davies-Bouldin	Silhouette: cohesión y separación de los grupos, de −1 a 1 (más alto es mejor). Davies-Bouldin: similitud promedio entre grupos (más bajo es mejor). Inercia: suma de distancias al centro de cada grupo; siempre baja al aumentar k.
IQR y Z-score	IQR: Q3 − Q1; un valor fuera de [Q1 − 1,5·IQR, Q3 + 1,5·IQR] se marca como atípico. Z-score: distancia a la media en desviaciones estándar; $\|z\| > 3$ se marca como atípico.
Yeo-Johnson	Transformación de potencia que acerca una variable a la normal y admite ceros y negativos; el exponente λ se ajusta con los datos de entrenamiento.

Término	Qué significa
One-Hot y ordinal	One-Hot: una columna 0/1 por categoría (menos una de referencia). Ordinal: un entero que respeta el orden natural de las categorías.
Fuga de datos	Cuando el modelo recibe información que no tendría al momento de predecir o que proviene del conjunto de prueba; infla las métricas sin mejorar el modelo.

Tabla 25. Términos usados en el informe.

B Cómo reproducir el proyecto

El repositorio https://github.com/itspablito/DatosSinCiencia2y3 contiene los tres notebooks (`fase_a_eda`, `fase_b_limpieza`, `fase_c_modelos`), el archivo `datos_limpios.parquet`, este informe y la presentación. El CSV original (≈27 MB) no está en el repositorio; debe descargarse y guardarse junto al README.

1. Copiar `.env.example` a `.env`; si el CSV está en otra carpeta, editar `RUTA_CSV` (ruta relativa a `entrega/`).
2. Crear el entorno virtual con Python 3.10 o superior, activarlo e instalar las dependencias con `pip install -r requirements.txt`.
3. Desde la carpeta `entrega/`, abrir Jupyter y ejecutar los notebooks en orden: A (gráficos e insights), B (genera `datos_limpios.parquet`) y C (métricas y comparación de modelos).

Las figuras de este informe se regeneraron a partir del CSV y del parquet con la misma preparación de los notebooks y un estilo unificado; las cifras coinciden con las salidas de los notebooks. La curva ROC, el AUC y la gravedad por segmento de K-Means se calcularon aparte con las mismas configuraciones y semilla; el accuracy y el F1 macro de los tres modelos re-entrenados coinciden con los del notebook. La proyección PCA (Figura 22) se tomó directamente del notebook de la Fase C.

C Inventario de gráficos de los notebooks

Notebook	Gráficos
Fase A (15)	Barras de faltantes por columna · mapa de calor de faltantes por año · histogramas de las 7 variables numéricas · histograma y KDE de reportes por día · boxplots de conteos (IQR) · boxplots de reportes por día según el año · matrices de correlación de Pearson y Spearman · barras de gravedad · línea de reportes por mes · líneas de promedio diario por gravedad y año · barras apiladas por actor vial · Pareto de vehículos · violín y barras por día de la semana · barras apiladas por clase de accidente · barras horizontales de direcciones.
Fase B (4)	Boxplots y barras del número de vehículos antes de tratar outliers · faltantes por variable antes de imputar · conteos original vs. log(1 + x) vs. Yeo-Johnson (3 × 3) · distribuciones antes y después de escalar.
Fase C (7)	Tres matrices de confusión · barras comparativas de métricas · Silhouette y Davies-Bouldin según k · perfil de vehículos por segmento · proyección PCA de los segmentos.

Tabla 26. Gráficos disponibles en los notebooks del repositorio, cada uno con su interpretación.