GRUPO DATOSSINCIENCIA · FASE D

# Siniestralidad vial en Santiago de Cali, 2016-2024

## Conclusiones y Presentación Final · Proyecto 2 y 3: Análisis, Limpieza y Modelado

Secretaría de Movilidad de Cali · 370.996 reportes tras la limpieza

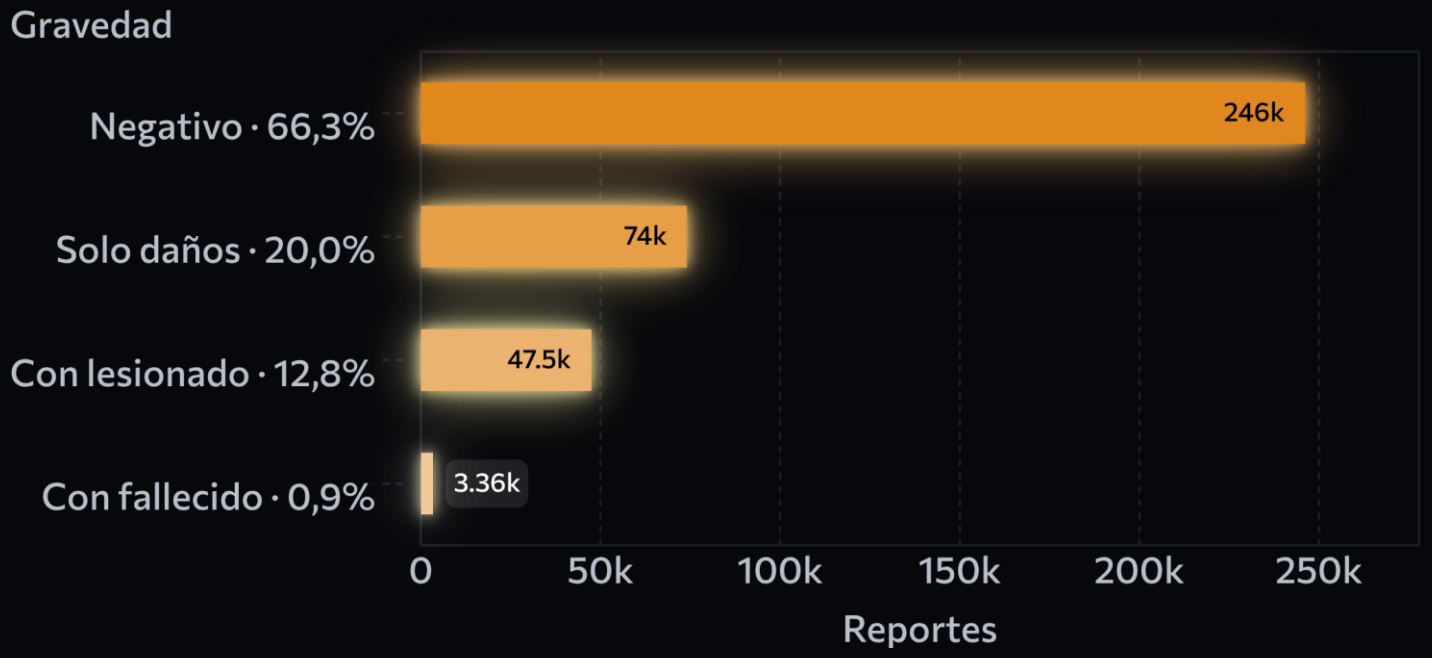
Integrantes: Juan José Wallens · Juan José Guzmán · Natalia Martínez · Jesús Guzmán · Juan Pablo Rodríguez

Introducción a la Ciencia de los Datos
Docente: Héctor Fabio Ocampo Arbeláez · 28 de octubre de 2026

PROBLEMA Y DATOS

# La gravedad de un siniestro puede estudiarse con los datos que hoy se capturan

¿Qué características se asocian con la gravedad para focalizar la prevención y priorizar la atención?




## 370.996 reportes

Fecha, dirección, clase de accidente, medio de reporte y vehículos implicados.

Cuatro clases ordenadas. La menos frecuente, «Con fallecido», es la más costosa.

ANÁLISIS EXPLORATORIO

# El registro cambió con el tiempo: menos reportes no es una ciudad más segura




## El registro no es estable

Los reportes caen desde marzo de 2020; los fallecidos se mantienen entre 360 y 450 por año.

## Los huecos también informan

Falta la clase de accidente en 87,7% y el dato de vehículos en 81% de los «Negativo».

Implicación: focalizar por actor vial y evitar que el modelo aprenda del hueco en vez del siniestro.

PREPARACIÓN DE DATOS

# La limpieza dejó 370.996 filas sin faltantes, decidiendo según la causa de cada hueco

371.003 filas originales → 370.996 · Hasta 87,7% de faltantes → 0% en variables tratadas

## Depurar y unificar

Se retiraron 1 fila vacía, 4 duplicados y 2 filas sin gravedad. Clase: 14 a 6 variantes; medio: 17 a 4; vehículos: 54 tipos a 6 grupos.

## Tratar según el origen

Mediana de train más indicador en conteos. «SIN REGISTRO» cuando el campo no existía, sin inventar unos 290 mil valores.

## Conservar lo plausible

IQR y Z-score: solo se trataron 2 valores imposibles, 12 y 16 vehículos. Con IQR = 0 se marcaba el 16% de datos reales.

## Transformar sin fuga

Yeo-Johnson: asimetría de +1,12 a 0,50. One-Hot, ordinal, Z-score y Min-Max, ajustados solo con train.

No se comparó el desempeño con y sin limpieza: no se afirma una mejora del modelado.

DISEÑO EXPERIMENTAL

# Un flujo único: partición 80/20 antes de transformar, tres clasificadores y un K-Means

01

## Partir

Estratificación 80/20.
Train: 296.796
Test: 74.200

02

## Transformar

20 predictoras. Ajuste de imputación, codificación y escalado solo con train.

03

## Modelar

Logística, árbol de profundidad 8 y Random Forest de 200 árboles. K-Means sin gravedad.

04

## Evaluar

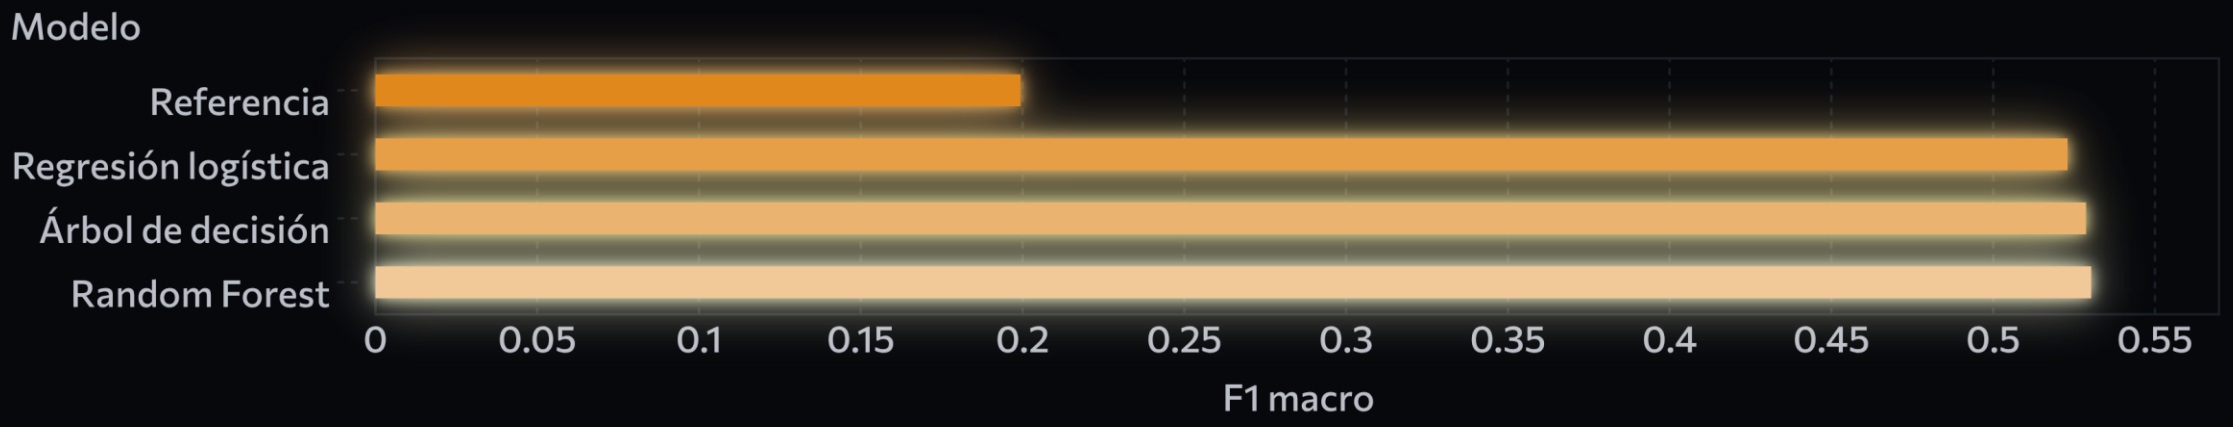
Solo en test: accuracy, F1 macro y recall de «Con fallecido».

Los datos de prueba no participan en el ajuste.

`Clasificadores: class_weight balanced · semilla 42 · sin búsqueda de hiperparámetros`
`Referencia «siempre Negativo»: accuracy 0,6634 · F1 macro 0,1994`

RESULTADOS EN TEST

# Los tres modelos superan la referencia, pero quedan muy cerca entre sí




| Modelo | Accuracy | Precision macro | Recall macro | F1 macro | AUC macro |
|---|---|---|---|---|---|
| Regresión logística | 0,7243 | 0,5107 | 0,6369 | 0,5230 | 0,815 |
| Árbol de decisión | 0,7270 | 0,5164 | 0,6394 | 0,5287 | 0,836 |
| Random Forest | 0,7256 | 0,5182 | 0,6448 | 0,5303 | 0,841 |

Random Forest supera al árbol en F1 macro por 0,0016; el árbol lidera accuracy. Ninguno domina todos los criterios.

ELECCIÓN Y LÍMITES

# Random Forest es el modelo elegido por F1 macro, con límites claros

F1 macro **0,5303**: cada clase pesa igual, aunque «Con fallecido» representa el 0,91%.

## 62,8%

### Recall en fallecidos

422 de 672 detectados.

## 10,3%

### Precisión en fallecidos

Solo una de cada diez alertas es correcta.

## 3.666

### Falsas alarmas

AUC de fallecidos: 0,90; clases intermedias: 0,82.

Alternativas: árbol por reglas legibles; logística por recall en fallecidos de 63,8%.

Útil para estudiar registros históricos, no como criterio único ni como prueba de anticipación.

SEGMENTACIÓN SIN GRAVEDAD

# K-Means encontró seis perfiles de reportes, definidos sobre todo por el actor vial

k = 6, mejor entre k = 2 a 10 · Silhouette 0,4334 · Davies-Bouldin 0,6672

| Grupo | Perfil | Cruce descriptivo con gravedad |
|---|---|---|
| 0 | Cerca del 76% de reportes | 5,1% con lesionados |
| 1 | Bicicletas | 61,0% con lesionados; grupo pequeño |
| 2 | Transporte público | Perfil por actor vial |
| 3 | Carga | Perfil por actor vial |
| 4 | Motos | 42,3% con lesionados |
| 5 | Otros vehículos | Grupo pequeño; interpretar con cautela |

Test: Silhouette 0,4261 · Davies-Bouldin 0,6779. PCA: 32,35% de varianza, solo para visualizar.

Los identificadores no son niveles de riesgo; el cruce con gravedad no establece causalidad.

INTERPRETACIÓN Y TRABAJO FUTURO

# La gravedad depende del actor vial; los modelos sirven para estudiar, no para decidir casos

## Lo que se observó

- Bicicleta y moto concentran lesionados y fallecidos; la segmentación coincide.
- Faltantes ligados a cambios del formulario.
- F1 macro 0,52-0,53 y seis perfiles descriptivos.
- Una partición, precisión fatal de 10,3%, sin hora ni ubicación; vehículos pueden conocerse al confirmar el reporte.

## Lo que se propone

- Validación cruzada y evaluación por año.
- Ajustar hiperparámetros, probar Gradient Boosting y umbral para fallecidos.
- Incluir hora, ubicación, clima y estado de la vía.
- Formulario estable, campos obligatorios y más datos de fallecidos.

CONCLUSIONES · GRUPO DATOSSINCIENCIA

# Tres conclusiones y un aporte para focalizar la prevención

01 **Análisis**

La gravedad se asocia sobre todo con el actor vial: bicicleta y moto concentran lesionados y fallecidos.

02 **Limpieza**

Entender por qué falta cada dato definió las decisiones y qué variables excluir.

03 **Modelado**

Los tres clasificadores superan la referencia, con diferencias mínimas y baja precisión en fallecidos.

Un proceso reproducible de análisis, limpieza y modelado que orienta qué mejorar en el registro y dónde focalizar la prevención.